

LAPORAN PRAKTIK KERJA LAPANG

**PERBANDINGAN ARSITEKTUR CONVOLUTIONAL NEURAL
NETWORK (CNN) DALAM IDENTIFIKASI SPESIES TANAMAN
HOYA BERDASARKAN CITRA BUNGA DI BRIN SAMAUN
SAMADIKUN BANDUNG**

Oleh:
Citra Mayzahra Putri
225100200111039



**DEPARTEMEN TEKNIK BIOSISTEM
FAKULTAS TEKNOLOGI PERTANIAN
UNIVERSITAS BRAWIJAYA
2025**

LEMBAR PERSETUJUAN

LAPORAN PRAKTIK KERJA LAPANG

PERBANDINGAN ARSITEKTUR *CONVOLUTIONAL NEURAL NETWORK* (CNN) DALAM IDENTIFIKASI SPESIES TANAMAN HOYA BERDASARKAN CITRA BUNGA DI BRIN SAMAUN SAMADIKUN BANDUNG

Nama : Citra Mayzahra Putri
NIM : 225100200111039
Departemen : Teknik Biosistem
Fakultas : Teknologi Pertanian

Telah disetujui oleh

Mengetahui
Ketua Departemen

Dosen Pembimbing,

Dr.Eng. Akhmad Adi Sulianto, STP., MT., M.Eng
NIP. 197905012005011001

Rini Yulianingsih, STP., MT., Ph.D
NIP. 197407172008122002

Tanggal Persetujuan:

Tanggal Persetujuan:

**LEMBAR PENGESAHAN
LAPORAN PRAKTIK KERJA LAPANG**

**PERBANDINGAN ARSITEKTUR CONVOLUTIONAL NEURAL NETWORK
(CNN) DALAM IDENTIFIKASI SPESIES TANAMAN HOYA BERDASARKAN
CITRA BUNGA DI BRIN SAMAUN SAMADIKUN BANDUNG**

Nama : Citra Mayzahra Putri
NIM : 225100200111039
Program Studi : Teknik Pertanian dan Biosistem
Departemen : Teknik Biosistem
Fakultas : Teknologi Pertanian

Telah disetujui oleh:
Pembimbing Lapangan, Dosen Pembimbing

Siti Kania Kushadiani, S.T., M.Kom. Rini Yulianingsih, STP., MT., Ph.D
NIP. 197906042002122007 NIP. 197407172008122002

Mengetahui,
Ketua Departemen Dosen Penguji,

Dr. Eng. Akhmad Adi Sulianto, STP., MT., Prof. Dr. Widya Dwi Rukmi Putri, S.TP.,
M.Eng M.P.
NIP. 197905012005011001 NIP. 197005041999032002

KATA PENGANTAR

Puji syukur kehadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga proposal kegiatan Praktik Kerja Lapangan (PKL) yang berjudul "**Perbandingan Arsitektur Convolutional Neural Network (CNN) dalam Identifikasi Spesies Tanaman Hoya Berdasarkan Citra Bunga di BRIN Samaun Samadikun Bandung**" ini dapat terselesaikan dengan baik. Proposal ini disusun sebagai salah satu syarat untuk melaksanakan PKL di Badan Riset dan Inovasi Nasional (BRIN) Bandung. Kegiatan ini diharapkan dapat memberikan pengetahuan dan pengalaman berharga, khususnya dalam penerapan teknologi kecerdasan buatan (AI) untuk identifikasi dan karakterisasi fenotip varietas cabai unggul.

Pada kesempatan ini, penulis juga mengucapkan terima kasih yang sebesar-besarnya kepada semua pihak yang telah memberikan dukungan dan bimbingan, baik secara langsung maupun tidak langsung, selama proses penyusunan laporan ini, di antaranya:

1. Allah SWT yang selalu memberikan rahmat, petunjuk, serta kekuatan dalam menyelesaikan proposal ini.
2. Yang tercinta, Ayah dan Ibu serta keluarga yang telah memberikan dukungan, motivasi, dan doa.
3. Ibu Rini Yulianingsih STP., MT., Ph.D yang telah memberikan arahan dan masukan.
4. Ibu Siti Kania Kushadiani, S.T., M.Kom selaku dosen PKL yang senantiasa membimbing dan memberi masukan, kritik, serta saran
5. Bapak Dr. Esa Prakasa, M.T. selaku Ketua Pusat Riset Sains Data dan Informasi, yang senantiasa memberikan bantuan dan motivasi
6. BRIN, KST Samaun Samadikun BRIN, Gedung 10 sebagai tempat Praktek Kerja Lapang
7. Sahabat-sahabat PKL saya yang telah memberikan dukungan dan bantuan selama kegiatan PKL berlangsung

Penulis menyadari bahwa proposal ini masih memiliki kekurangan. Oleh karena itu, kritik dan saran yang konstruktif sangat diharapkan untuk perbaikan di masa mendatang. Sebagai penutup, semoga proposal ini dapat memberikan manfaat dan kontribusi positif bagi semua pihak yang terkait.

Malang, 27 Februari 2025



Citra Mayzahra Putri

ABSTRAK

PERBANDINGAN ARSITEKTUR CONVOLUTIONAL NEURAL NETWORK (CNN) DALAM IDENTIFIKASI SPESIES TANAMAN HOYA BERDASARKAN CITRA BUNGA DI BRIN SAMAUN SAMADIKUN BANDUNG

Oleh:
Citra Mayzahra Putri
225100200111039

Hoya merupakan salah satu tanaman hias yang memiliki keberagaman spesies dengan karakteristik morfologi yang unik. Identifikasi spesies Hoya menjadi sebuah tantangan tersendiri karena adanya kemiripan bentuk bunga antarspesies. Oleh karena itu, penelitian ini bertujuan untuk membandingkan performa dua arsitektur *Convolutional Neural Network* (CNN) dalam mengklasifikasikan spesies Hoya berdasarkan citra bunga. Dalam penelitian ini, *dataset* citra bunga Hoya diperoleh dari dua sumber sekunder yaitu RIN Dataverse dan dari internet (melalui website plantnet dan vermonthoyas). *Dataset* tersebut mencakup lima spesies Hoya, yaitu *Hoya amicabilis*, *Hoya campanulata white*, *Hoya multiflora*, *Hoya rigidifolia*, dan *Hoya scortechinii*. Proses penelitian meliputi beberapa tahapan utama, yaitu *image collection*, *data preprocessing*, *modelling*, dan *evaluation*. Dua arsitektur CNN yang digunakan untuk perbandingan adalah MobileNetV2 dan DenseNet121, yang sering digunakan dalam klasifikasi citra. Model dilatih menggunakan parameter yang telah ditentukan, dan performa kedua arsitektur dievaluasi menggunakan *confusion matrix* untuk menganalisis tingkat akurasi prediksi pada setiap kelas. Hasil penelitian menunjukkan bahwa MobileNetV2 memiliki performa yang lebih unggul dibandingkan DenseNet121, dengan akurasi 97,37% pada *dataset* RIN Dataverse dan 93,55% pada *dataset* kombinasi (RIN Dataverse + Internet), sedangkan DenseNet121 memperoleh 96,00% pada *dataset* RIN Dataverse dan 95,92% pada *dataset* kombinasi (RIN Dataverse + Internet). Penelitian ini menunjukkan bahwa arsitektur MobileNetV2 lebih optimal dalam mengklasifikasikan spesies Hoya berdasarkan citra bunga dibandingkan DenseNet121. Oleh karena itu, arsitektur ini dapat menjadi rekomendasi dalam pengembangan sistem klasifikasi tanaman berbasis *deep learning*.

Kata kunci: Tanaman Hoya, Identifikasi, *Deep Learning*, *Convolutional Neural Network* (CNN), MobileNetV2, DenseNet121

DAFTAR ISI

LEMBAR PERSETUJUAN	ii
LEMBAR PENGESAHAN	iii
KATA PENGANTAR	iv
ABSTRAK.....	v
DAFTAR ISI	vi
DAFTAR TABEL	viii
DAFTAR GAMBAR	ix
DAFTAR LAMPIRAN.....	x
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Tujuan	2
1.2.1 Tujuan Umum	2
1.2.2 Tujuan Khusus	2
BAB II TINJAUAN PUSTAKA.....	3
2.1 Hoya	3
2.2 <i>Deep learning</i>	4
2.3 <i>Convolutional Neural Network</i>	5
2.4 <i>Image Processing</i>	6
BAB III METODE PELAKSANAAN	7
3.1 Waktu dan Tempat Pelaksanaan	7
3.2 Metode Pelaksanaan.....	8
3.3 Jadwal Kegiatan	8
BAB IV HASIL DAN PEMBAHASAN	10
4.1 Tinjauan Umum Perusahaan	10
4.1.1 Sejarah Perusahaan.....	10
4.1.2 Visi, Misi, dan Tujuan BRIN	11
4.1.3 Struktur Organisasi BRIN	12
4.1.4 Profil Pusat Riset Sains Data dan Informasi	13
4.2 <i>Image Collection</i>	14
4.3 Data <i>Preprocessing</i>	15
4.4 <i>Modelling</i>	16
4.4.1 MobileNetV2	17
4.4.2 DenseNet121.....	17
4.5 <i>Evaluation</i>	17
BAB V TUGAS KHUSUS	19
5.1 Studi Literatur	19
5.2 Data <i>Collecting</i>	19
5.3 Data <i>Preprocessing</i>	20
5.4 <i>Modelling</i>	21
5.4.1 <i>Dataset RIN Dataverse</i>	22
5.4.2 Kombinasi <i>Dataset RIN Dataverse</i> dengan <i>Dataset Internet</i>	28
5.5 Perbandingan Arsitektur.....	34
BAB VI PENUTUP	35
6.1 Kesimpulan.....	35

6.2 Saran	35
DAFTAR PUSTAKA	36
LAMPIRAN	38

DAFTAR TABEL

Tabel 3.1 Jadwal Kegiatan Praktik Kerja Lapang (PKL) di BRIN KST Samaun Samadikun	9
Tabel 4.1 <i>Confusion Matrix</i>	18
Tabel 5.1 Perbandingan Kinerja Arsitektur.....	34

DAFTAR GAMBAR

Gambar 2.1 Jenis-Jenis Tanaman Hoya (A: <i>Hoya lasiantha</i> ; B: <i>Hoya meredithii</i> ; C: <i>Hoya mitrata</i> ; D: <i>Hoya ranauensis</i>)	3
Gambar 2.2 Tahapan Arsitektur CNN	5
Gambar 3.1 Gedung Utama Badan Riset dan Inovasi Nasional.....	7
Gambar 3.2 Gedung BASICS BRIN KST Samaun Samadikun Bandung.....	7
Gambar 4.1 Logo Badan Riset dan Inovasi Nasional (BRIN)	11
Gambar 4.2 Struktur Organisasi BRIN.....	13
Gambar 4.3 Struktur Organisasi PRSDI	14
Gambar 4.4 Proses Augmentasi <i>Dataset</i>	16
Gambar 5.1 <i>Dataset</i> Tanaman Hoya	20
Gambar 5.2 Bunga Hoya di Augmentasi.....	20
Gambar 5.3 Code Pembagian <i>Dataset</i>	21
Gambar 5.4 Hasil Pelatihan dan Akurasi Model MobileNetV2	23
Gambar 5.5 Grafik Akurasi MobileNetV2	24
Gambar 5.6 Grafik <i>Confusion Matrix</i> MobileNetV2	25
Gambar 5.7 Hasil Pelatihan dan Akurasi Model DenseNet121.....	26
Gambar 5.8 Grafik Akurasi DenseNet121	27
Gambar 5.9 Grafik <i>Confusion Matrix</i> MobileNetV2	28
Gambar 5.10 Hasil Pelatihan dan Akurasi Model MobileNetV2	29
Gambar 5.11 Grafik Akurasi MobileNetV2	30
Gambar 5.12 Grafik <i>Confusion Matrix</i> MobileNetV2	31
Gambar 5.13 Hasil Pelatihan dan Akurasi Model DenseNet121	32
Gambar 5.14 Grafik Akurasi DenseNet121	33
Gambar 5.15 Grafik <i>Confusion Matrix</i> DenseNet121	34

DAFTAR LAMPIRAN

Lampiran 1. Surat Penerimaan PKL.....	38
Lampiran 2. Struktur Organisasi Pusat Riset Sains dan Data Informasi KST BRIN Samaun Samadikun Bandung	40
Lampiran 3. Kartu Kendali Pembimbing Lapang	41
Lampiran 4. Form Penilaian Kegiatan PKL	42
Lampiran 5. Dokumentasi Kegiatan PKL	43
Lampiran 6. <i>Literature Review</i>	45

BAB I

PENDAHULUAN

1.1 Latar Belakang

Indonesia merupakan negara kepulauan yang terletak di wilayah tropis, berada di antara Benua Asia dan Australia, serta diapit oleh Samudra Hindia dan Samudra Pasifik. Negara ini terdiri dari sekitar 17.500 pulau dengan garis pantai mencapai 95.181 km dan luas sekitar 9 juta km², yang mencakup 2 juta km² daratan dan 7 juta km² lautan. Meskipun luas wilayah ini hanya mencakup sekitar 1,3% dari total luas permukaan bumi, Indonesia memiliki tingkat keanekaragaman hayati yang sangat tinggi. Dalam hal keanekaragaman tumbuhan, Indonesia diperkirakan memiliki sekitar 25% dari seluruh spesies tumbuhan berbunga di dunia, menjadikannya sebagai negara dengan keanekaragaman tumbuhan terbesar ketujuh secara global (Kusmana dan Hikmat, 2015).

Salah satu kekayaan hayati Indonesia yang kaya potensi namun masih kurang dikenal luas adalah tanaman Hoya. Tanaman ini tergolong tanaman epifit dari suku Apocynaceae dan berasal dari wilayah tropis yang membentang dari India hingga Kepulauan Pasifik, termasuk Indonesia. Hoya memiliki berbagai potensi, baik dari segi pemanfaatan fungsional maupun nilai estetikanya. Di Indonesia, Hoya dimanfaatkan dalam pengobatan tradisional untuk mengatasi berbagai penyakit seperti luka gores, luka bakar, pembengkakan, infeksi kulit, batuk, asma, dan gangguan pencernaan. Di negara lain seperti Jerman, tanaman ini bahkan digunakan sebagai alternatif pengganti insulin (Afifah *et al.*, 2017). Selain itu, keunikan bentuk bunga dan daunnya menjadikan Hoya populer sebagai tanaman hias. Beberapa spesies memiliki daun dengan bentuk yang khas dan sifat pertumbuhannya yang merambat memungkinkan penggunaannya sebagai elemen dekoratif ruangan.

Proses identifikasi dan klasifikasi spesies Hoya masih menghadapi berbagai tantangan. Salah satu kendala utama adalah kemiripan visual antarspesies yang seringkali menimbulkan kekeliruan dalam identifikasi. Selain itu, keterbatasan data yang terstandarisasi serta kurangnya metode klasifikasi yang efisien juga menjadi hambatan dalam mengoptimalkan pemanfaatan tanaman ini. Seiring perkembangan teknologi, khususnya di bidang kecerdasan buatan, peluang baru mulai terbuka untuk mengatasi permasalahan ini. Pemanfaatan *computer vision* dan *image processing* dapat menjadi alternatif solusi atas keterbatasan tenaga ahli dalam taksonomi tumbuhan, dengan pendekatan analisis citra berbasis morfologi, warna, dan tekstur daun (Pujiati dan Rochmawati, 2022).

Salah satu metode *deep learning* yang banyak digunakan dalam pengolahan citra adalah *Convolutional Neural Network* (CNN). Metode ini bekerja dengan membagi citra menjadi bagian-bagian kecil dan mengenali pola-pola penting seperti bentuk, tepi, dan tekstur melalui proses pembelajaran berlapis. CNN memiliki kemampuan mengekstraksi fitur visual secara otomatis, sehingga dapat dimanfaatkan untuk klasifikasi gambar dengan tingkat akurasi yang tinggi (Septian dan Suhendar, 2024). Melalui pendekatan ini, proses identifikasi tanaman dapat dilakukan secara lebih efisien dan konsisten dibandingkan metode konvensional yang cenderung memerlukan waktu dan tenaga lebih banyak (Sun *et al.*, 2023).

Oleh karena itu, CNN dinilai menjadi salah satu solusi yang menjanjikan dalam mendukung proses klasifikasi dan identifikasi spesies Hoya berbasis citra bunga.

Kegiatan Praktik Kerja Lapang (PKL) dilaksanakan di Badan Riset dan Inovasi Nasional (BRIN), sebuah lembaga pemerintah yang berada di bawah dan bertanggung jawab langsung kepada Presiden berdasarkan Peraturan Presiden Nomor 78 Tahun 2021. BRIN berperan dalam penyelenggaraan kegiatan penelitian, pengembangan, pengkajian, penerapan, serta kegiatan inovasi dan invensi, termasuk dalam bidang ketenaganukliran dan keantarksaan. Dalam mendukung ekosistem riset nasional, BRIN juga menjalin kerja sama dengan akademisi, mahasiswa, dan pihak industri. Kegiatan PKL ini dilaksanakan di Satuan Kerja Pusat Riset Sains Data dan Informasi (PRSDI), yang merupakan bagian dari Organisasi Riset Elektronika dan Informatika. PKL dilaksanakan selama satu bulan, dimulai pada 6 Januari hingga 6 Februari 2025, dan berlokasi di KST Samaun Samadikun, Bandung, Jawa Barat.

1.2 Tujuan

1.2.1 Tujuan Umum

Tujuan umum pelaksanaan PKL ini yaitu:

1. Mengaplikasikan pengetahuan dan kemampuan mahasiswa sebagai tindakan Tridharma Perguruan Tinggi.
2. Melatih mahasiswa untuk bekerja mandiri dan bekerjasama di lingkungan profesional serta praktisi di lapang dan sekaligus berlatih menyesuaikan diri dengan kondisi lapang pekerjaan yang nantinya akan ditekuni setelah lulus.
3. Menambah wawasan dan pengalaman mengenai kondisi dalam lingkungan pekerjaan untuk persiapan memasuki dunia kerja.
4. Menerapkan ilmu pengetahuan dan keterampilan yang telah didapatkan selama perkuliahan dalam bentuk PKL.

1.2.2 Tujuan Khusus

Tujuan khusus pelaksanaan PKL ini yaitu:

1. Memahami struktur organisasi dan operasional KST Samaun Samadikun BRIN.
2. Mempelajari riset di bidang biodiversitas tanaman Hoya yang diterapkan di BRIN.
3. Memahami tahapan yang terlibat dalam proses pengembangan model *deep learning*, mulai dari pengumpulan data hingga penerapannya dalam pengolahan citra daun pada tanaman Hoya.

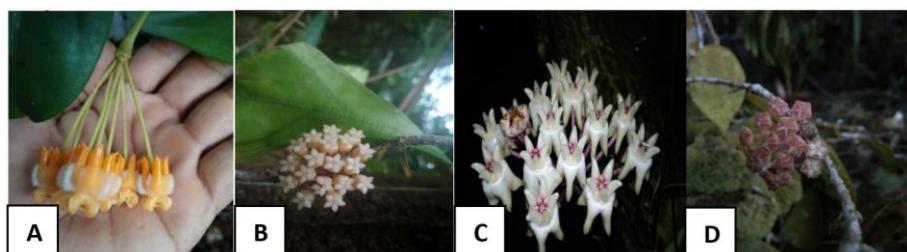
BAB II

TINJAUAN PUSTAKA

2.1 Hoya

Hoya adalah tumbuhan yang berasal dari keluarga *Apocynaceae* dan subkeluarga *Asclepiadoideae*. Di Amerika Serikat dan Eropa, Hoya dikenal sebagai bunga lilin atau bunga porselen. Keindahan bentuk dan warna bunganya menjadikan Hoya berpotensi sebagai tanaman hias dengan nilai ekonomi yang tinggi (Annisa *et al.*, 2017). Hoya memiliki sebaran geografis yang luas, mulai dari Jepang hingga Kepulauan Fiji dan Samoa, beberapa wilayah di Selandia Baru, daerah tropis Australia, Madagaskar, India, kawasan Indochina, dan bagian selatan Cina. Keragaman tertingginya ditemukan di wilayah Malesiana dan Indonesia diperkirakan menjadi pusat keanekaragaman spesies Hoya. Secara umum, Hoya memiliki ukuran batang kecil dengan diameter sekitar 2-8 mm. Tumbuhan ini biasanya menghasilkan getah berwarna putih. Daunnya tersusun bersilang berhadapan, memiliki lapisan lilin di permukaannya, dan bentuk daun yang bervariasi. Bunganya berbentuk majemuk dan tersusun dalam tandan yang menyerupai payung atau umbel, dan tandanya muncul diantara dua tangkai daun (interpetioler) (Firdiana dan Renjana, 2019). Hoya memiliki dua jenis daun yaitu sukulen dan non-sukulen. Daun non-sukulen memiliki ciri khas yaitu ukuran yang lebar, tidak berdaging, dan kutikula yang tipis (Hakim *et al.*, 2013). Karakteristik daun sukulen yaitu memiliki kemampuan menyimpan air di dalam organnya. Daun sukulen menjadi salah satu ciri tumbuhan xerofit. Tumbuhan xerofit adalah tumbuhan yang mampu beradaptasi dengan kondisi lingkungan yang ekstrem, terutama saat periode kekeringan (Hafiz *et al.*, 2013).

Hoya adalah tumbuhan epifit atau litofit. Sebagai epifit, Hoya tumbuh menempel pada pohon lain dan sebagai litofit, Hoya tumbuh menempel pada bebatuan yang mengandung humus. Pada umumnya, Hoya ditemukan di tempat dengan kelembapan tinggi dan paparan sinar matahari yang cukup. Contoh habitat Hoya meliputi bukit kapur di dekat pantai atau danau, hutan kerangas, pantai, hutan rawa gambut, serta pinggir sungai dan danau (Hakim *et al.*, 2013). Secara global, diperkirakan terdapat sekitar 150-200 jenis Hoya, dengan 50-60 jenis di antaranya ditemukan di Indonesia. Di Indonesia, sebanyak 32 jenis Hoya telah dikonservasi, salah satunya di Kebun Raya Bogor (Mayrantie *et al.*, 2021). Contoh gambar untuk masing-masing jenis tanaman Hoya dapat dilihat pada **Gambar 2.1**.



Gambar 2.1 Jenis-Jenis Tanaman Hoya (A: *Hoya lasiantha*; B: *Hoya meredithii*; C: *Hoya mitrata*; D: *Hoya ranauensis*)

Sumber: Mayrantie *et al.*, 2021

Menurut Afifah *et al.* (2017), tanaman Hoya memiliki berbagai potensi yang perlu dikembangkan lebih lanjut. Di Indonesia, tanaman ini dimanfaatkan sebagai obat untuk berbagai penyakit, seperti luka gores, luka bakar, pembengkakan, bisul, penyakit kulit akibat mikroorganisme, gangguan pencernaan, batuk, asma, penyakit paru-paru, hingga gangguan sendi. Di Jerman, Hoya telah digunakan sebagai bahan alternatif pengganti insulin. Selain sebagai bahan obat, Hoya juga digunakan sebagai pestisida nabati. Sebagai contoh yaitu masyarakat Kalimantan menggunakan tanaman ini untuk mengatasi hama ulat pada tanaman padi. Di samping itu, Hoya memiliki nilai estetika yang tinggi dan sering dimanfaatkan sebagai tanaman hias karena bunganya yang unik, indah, dan bervariasi. Sifat pertumbuhannya yang merambat memudahkan tanaman ini untuk dibentuk menjadi tanaman hias untuk dekorasi ruangan.

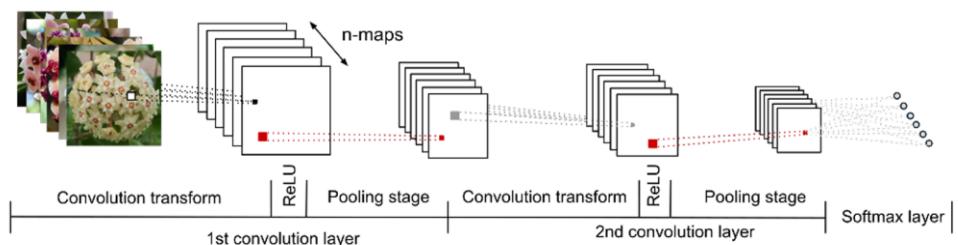
2.2 Deep learning

Deep learning merupakan cabang dari kecerdasan buatan dan *machine learning* yang mengembangkan jaringan saraf tiruan *multi-layer* untuk meningkatkan ketepatan atau akurasi dalam berbagai tugas, seperti deteksi objek, pengenalan suara, penerjemahan bahasa, dan lainnya. Berbeda dengan teknik *machine learning* tradisional, *deep learning* secara otomatis mampu mempelajari representasi data, seperti gambar, video, atau teks, tanpa memerlukan aturan kode atau pengetahuan domain tertentu dari manusia. *Deep learning* adalah kumpulan algoritma dalam *machine learning* yang menganalisis data pada berbagai tingkatan abstraksi. Proses ini biasanya memanfaatkan jaringan saraf tiruan, di mana setiap lapisan dalam model statistik mewakili konsep dengan tingkat kompleksitas yang berbeda. Konsep yang lebih kompleks disusun dari konsep-konsep dengan tingkat yang lebih rendah, sementara konsep tingkat rendah menjadi dasar untuk membentuk konsep tingkat yang lebih tinggi. Selain itu, *deep learning* merupakan subbidang dari *machine learning* yang algoritmanya terinspirasi oleh struktur otak manusia, dikenal sebagai *Artificial Neural Networks* (ANN). Jaringan ini pada dasarnya terdiri dari tiga atau lebih lapisan ANN. *Deep learning* mempunyai kemampuan untuk mempelajari dan beradaptasi dengan data dalam jumlah besar, serta mampu menyelesaikan berbagai masalah kompleks yang sulit diatasi oleh algoritma machine learning lainnya (Raup *et al.*, 2022).

Penelitian mengenai penerapan *deep learning* terhadap tanaman Hoya telah dilakukan oleh Laxmi *et al* (2022). Penelitian tersebut bertujuan untuk mengidentifikasi tanaman Hoya berdasarkan citra bunga, dengan hasil akurasi mencapai 90,476% dari 262 gambar menggunakan metode CNN dan transfer learning. Penelitian lain juga dilakukan oleh Fitriyah *et al* (2023) yang mengidentifikasi spesies tanaman Hoya berdasarkan citra daun dan bunga, dengan hasil akurasi sebesar 76,09% (untuk daun) dan 67,89% (untuk bunga) dari 1113 gambar (412 gambar bunga, 701 gambar daun) menggunakan metode CNN. Sementara itu, penelitian lain yang dilakukan oleh Noverina *et al* (2024) yang mengidentifikasi tanaman Hoya sebagai tanaman obat berdasarkan citra daun dengan akurasi mencapai 80% dari 71 gambar menggunakan metode CNN.

2.3 Convolutional Neural Network

Convolutional Neural Network (CNN) adalah salah satu algoritma dalam *deep learning* yang dirancang untuk mengolah data dua dimensi, seperti gambar. Secara teknis, CNN adalah sebuah arsitektur yang dapat dilatih dan terdiri dari beberapa tahapan (Pujiati dan Rochmawati, 2022). Arsitektur CNN dirancang dengan lapisan-lapisan khusus yang memungkinkan untuk ekstraksi fitur secara hierarkis dari data gambar. Cara kerja dari CNN mirip dengan *Multilayer Perceptron* (MLP), tetapi setiap neuron dalam CNN diwakili dalam bentuk dua dimensi (Wardani dan Leonardi, 2023). Secara umum, CNN memiliki struktur yang terdiri dari empat komponen utama, yaitu *input*, proses ekstraksi fitur, klasifikasi, dan *output*. Proses ekstraksi fitur dalam CNN dilakukan melalui beberapa lapisan, seperti lapisan konvolusi (*convolutional layer*), fungsi aktivasi (menggunakan ReLU), serta lapisan *pooling*. Sementara itu, proses klasifikasi dilakukan menggunakan *fully-connected layer* dan fungsi aktivasi (menggunakan Softmax). CNN bekerja secara bertahap, di mana *output* dari satu lapisan digunakan sebagai *input* untuk lapisan berikutnya hingga mencapai hasil akhir berupa klasifikasi dari *input* yang telah dimasukkan sebelumnya. Tahapan pertama dalam algoritma CNN dimulai dengan lapisan konvolusi, yang menghitung operasi konvolusi antara matriks citra dengan filter tertentu. Hasil dari operasi konvolusi ini kemudian diproses menggunakan fungsi aktivasi *Rectified Linear Unit* (ReLU) untuk menyederhanakan nilai *output*. Selanjutnya, hasil dari aktivasi ReLU diteruskan ke lapisan *max pooling*, yang berfungsi untuk mengurangi dimensi citra sambil mempertahankan fitur-fitur penting. Setelah melalui tahap *pooling*, hasilnya diratakan (*flattening*) menjadi satu dimensi agar lebih mudah diproses oleh lapisan *fully-connected* untuk klasifikasi gambar. Hasil dari proses *flattening* kemudian dimasukkan ke dalam *fully-connected layer* yang menggunakan algoritma Softmax. Langkah terakhir dalam proses adalah menghitung nilai loss menggunakan metode *Cross-entropy loss*. Metode ini dinilai efektif dalam meningkatkan performa model, terutama dengan fungsi aktivasi sigmoid dan Softmax pada *fully-connected layer*, yang sebelumnya cenderung mengakibatkan kejemuhan dan pembelajaran lambat jika menggunakan fungsi *loss* seperti *mean squared loss* (Darojat et al., 2021). Tahapan arsitektur CNN dapat dilihat pada **Gambar 2.2**



Gambar 2.2 Tahapan Arsitektur CNN

Sumber: Laxmi et al., 2022

2.4 *Image Processing*

Pengolahan citra atau *image processing* adalah teknik yang digunakan untuk memodifikasi gambar digital dengan tujuan untuk meningkatkan kualitasnya atau mengekstrak informasi penting. Salah satu tantangan utama dalam pengolahan citra adalah menghilangkan *noise* yang dapat mengurangi kejelasan detail gambar. Teknik yang sering diterapkan untuk mengatasi hal ini adalah *smoothing image* atau perataan gambar, yang berfungsi untuk mengurangi noise sekaligus meningkatkan kualitas visual gambar (Fauziyah *et al.*, 2024). Teknologi pengolahan citra, atau *image processing*, adalah metode pemrosesan sinyal dengan *input* berupa gambar (*image*) dan menghasilkan *output* berupa gambar lain menggunakan teknik tertentu. Proses ini bertujuan untuk memperbaiki kesalahan dalam data sinyal gambar yang mungkin muncul selama akuisisi atau transmisi, serta meningkatkan kualitas visual gambar agar lebih mudah dipahami oleh sistem penglihatan manusia. Melalui manipulasi dan analisis gambar, pengolahan citra memungkinkan peningkatan ketajaman serta kejelasan suatu objek dalam gambar. Aplikasi pengolahan citra memudahkan pengguna dalam proses pengenalan pola, yang memungkinkan pemisahan objek dari latar belakang secara otomatis. Setelah itu, objek yang terdeteksi akan diproses lebih lanjut oleh sistem pengklasifikasi. Selain itu, teknologi ini juga membantu mesin dalam mengenali bentuk tertentu, sehingga memudahkan proses identifikasi suatu objek (Ghifari *et al.*, 2022).

BAB III

METODE PELAKSANAAN

3.1 Waktu dan Tempat Pelaksanaan

Pelaksanaan Praktik Kerja Lapang (PKL) akan dilaksanakan di Badan Riset dan Inovasi Nasional (BRIN), KST Samaun Samadikun, yang berlokasi di Jl. Sangkuriang, Dago, Kecamatan Coblong, Kota Bandung, Jawa Barat. Durasi PKL ini berlangsung selama sebulan, mulai dari tanggal 6 Januari 2025 hingga 6 Februari 2025. Pelaksanaaan PKL mengikuti waktu operasional di KST Samaun Samadikun BRIN, yaitu pada hari Senin – Kamis pukul 07.30 - 16.00 WIB dan pada hari Jum'at pukul 07.30 - 16.30 WIB.



Gambar 3.1 Gedung Utama Badan Riset dan Inovasi Nasional
KST Samaun Samadikun
Sumber: Dokumentasi Pribadi, 2025



Gambar 3.2 Gedung BASICs BRIN KST Samaun Samadikun Bandung
Sumber: Dokumentasi Pribadi, 2025

3.2 Metode Pelaksanaan

Pelaksanaan Praktik Kerja Lapang (PKL) selama di BRIN KST Samaun Samadikun bertujuan untuk membandingkan arsitektur Convolutional Neural Network (CNN) dalam identifikasi spesies tanaman Hoya berdasarkan citra bunga. Metode yang digunakan dalam pelaksanaan PKL ini terdiri dari beberapa tahapan, yaitu:

1. Observasi

Penulis akan memantau langsung aktivitas dan proses kerja terkait pengembangan teknologi deep learning di BRIN KST Samaun Samadikun. Tujuannya adalah untuk memperoleh pemahaman umum mengenai dinamika kerja serta interaksi antar individu di lingkungan tersebut.

2. Wawancara

Metode wawancara dilakukan untuk mengumpulkan informasi yang lebih rinci dan spesifik dari sumber-sumber yang relevan. Melalui wawancara, praktikan dapat mengajukan pertanyaan mendalam kepada peneliti, staf, manajer, atau pihak terkait lainnya yang berhubungan dengan fokus dari PKL.

3. Praktik Langsung

Metode ini memberikan kesempatan kepada penulis untuk terlibat secara langsung dalam berbagai aspek pekerjaan di Pusat Riset Sains Data dan Informasi BRIN KST Samaun Samadikun. Keterlibatan ini memungkinkan penulis untuk memperoleh pengalaman langsung dan pemahaman praktis mengenai penerapan teori dalam kegiatan lapangan.

4. Dokumentasi

Metode dokumentasi melibatkan pengumpulan, perekaman, dan penyimpanan data serta informasi atau temuan yang relevan selama PKL berlangsung. Dokumentasi yang sistematis membantu untuk memastikan bahwa semua informasi utama terkait penerapan teknologi deep learning terdokumentasi dengan baik dan dapat dijadikan referensi dalam penyusunan laporan PKL.

5. Studi Literatur

Untuk memperdalam pemahaman mengenai konteks dan informasi yang berkaitan dengan topik PKL, penulis akan melakukan studi literatur. Studi ini dilakukan dengan mengkaji dokumen, publikasi ilmiah, jurnal, serta sumber-sumber lain yang relevan dengan fokus PKL. Studi literatur dapat membantu penulis memperoleh wawasan yang lebih luas untuk mendukung analisis hasil PKL dan memberikan landasan teoritis yang kuat mengenai fokus PKL.

3.3 Jadwal Kegiatan

Berikut adalah tabel yang menggambarkan aktivitas yang akan dilaksanakan selama Praktik Kerja Lapang di BRIN KST Samaun Samadikun:

Tabel 3.1 Jadwal Kegiatan Praktik Kerja Lapang (PKL) di BRIN KST Samaun Samadikun

No.	Nama Kegiatan	Pelaksanaan Kegiatan (Bulan/Minggu ke-)							
		Januari 2025				Februari 2025			
		1	2	3	4	1	2	3	4
1.	Persiapan Kegiatan Praktik Kerja Lapang								
2.	Pengenalan Lingkungan Kerja BRIN KST Samaun Samadikun								
3.	Pelaksanaan Praktik Kerja Lapang “Perbandingan Arsitektur <i>Convolutional Neural Network (CNN)</i> dalam Identifikasi Spesies Tanaman Hoya Berdasarkan Citra Bunga di BRIN Samaun Samadikun Bandung”								
4.	Pelaksanaan Tugas Khusus								
5.	Studi Literatur								
6.	Pengolahan Data								
7.	Penyusunan Laporan dan Konsultasi								
8.	Pengumpulan Laporan								

BAB IV

HASIL DAN PEMBAHASAN

4.1 Tinjauan Umum Perusahaan

4.1.1 Sejarah Perusahaan

Berdasarkan Peraturan Presiden Nomor 78 Tahun 2021, Badan Riset dan Inovasi Nasional atau BRIN merupakan lembaga pemerintah yang berada di bawah naungan presiden dan bertanggung jawab dalam melaksanakan penelitian, pengembangan, pengkajian, dan penerapan, serta inovasi dan inovasi, pengelolaan ketenaganukliran, serta penyelenggaraan keantariksaan yang terintegrasi. Sejarah perkembangan BRIN berawal dari upaya Presiden Soekarno dalam mendirikan institusi riset dan ilmu pengetahuan pada tahun 1952 dengan menunjuk Sarwono Prawirohardjo untuk mendirikan lembaga yang kemudian diberi nama Majelis Ilmu Pengetahuan Indonesia (MIPI) pada tahun 1956. MIPI menjadi wadah utama dalam pengembangan ilmu pengetahuan di Indonesia dan dipimpin oleh Sarwono Prawirohardjo. Kemudian aktivitas riset terus berkembang hingga terbentuk kolaborasi dengan B. J. Habibie dan Sumitro Joyohadikusumo, yang kemudian membentuk industri pesawat dalam negeri yang diwadahi melalui pendirian National Research Center Cibinong. Pada tahun 1967, pemerintah membubarkan Lemrenas dan MIPI, lalu mendirikan Lembaga Ilmu Pengetahuan Indonesia atau LIPI, yang bertanggung jawab dalam membina berbagai lembaga penelitian nasional. Perkembangan inovasi di bidang riset terus berlanjut dengan pendirian kawasan penelitian terbesar di Indonesia, yaitu Pusat Penelitian Ilmu Pengetahuan (PUSPIPTEK). Selain itu, dibangun juga kawasan reaktor nuklir G.A Siwabessy yang berkapasitas 30 MW, menjadikannya yang terbesar di Asia Tenggara. Perkembangan riset dan teknologi semakin terlihat setelah B. J. Habibie memegang jabatan sebagai Menteri Negara Riset dan Kepala dari Badan Pengkajian Penerapan Teknologi (BPPT) pada tahun 1978. Salah satu pencapaian penting pada masa di bawah kepemimpinannya adalah penerbangan perdana pesawat N-250 pada 10 Agustus 1945. Selanjutnya, perkembangan ilmu pengetahuan dan teknologi (IPTEK) dilakukan melalui sebuah pendekatan yang melibatkan perguruan tinggi serta kerja sama antara Kementerian Riset dan Teknologi dengan Direktorat Jenderal Pendidikan Tinggi. Pendekatan ini melahirkan Undang-Undang Sistem Nasional Ilmu Pengetahuan dan Teknologi (UU Sisnas IPTEK) sebagai pengganti regulasi yang sebelumnya diterbitkan pada tahun 2000. Perubahan regulasi ini menjadi landasan utama dalam pembentukan BRIN, yang bertujuan untuk memastikan ekonomi riset nasional berjalan lebih optimal. Hal ini kemudian diperkuat dengan penerbitan Peraturan Presiden mengenai pembentukan Kementerian Riset dan Teknologi/BRIN. Adapun logo BRIN dapat dilihat pada **Gambar 4.1**



Gambar 4.1 Logo Badan Riset dan Inovasi Nasional (BRIN)

Sumber: brin.go.id, 2025

Secara resmi BRIN dibentuk pada tanggal 5 Mei 2021 oleh Presiden Joko Widodo melalui penandatanganan Peraturan Presiden Nomor 33 Tahun 2021. Peraturan ini secara efektif menetapkan BRIN sebagai satu-satunya badan peneliti nasional di Indonesia. Dalam peraturan tersebut, seluruh badan penelitian nasional Indonesia seperti Lembaga Ilmu Pengetahuan Indonesia (LIPI), Badan Pengkajian dan Penerapan Teknologi (BPPT), Badan Tenaga Nuklir Nasional (BATAN), serta Lembaga Penerbangan dan Antariksa Nasional (LAPAN) dilebur menjadi satu di bawah BRIN. Sebagai Lembaga yang berdiri sendiri, BRIN tidak lagi berfungsi sebagai regulator, karena fungsi regulasi tetap berada di bawah kewenangan Kementerian terkait. Sebaliknya, BRIN beroperasi sebagai badan riset terintegrasi yang menyatukan BATAN, BPPT, LAPAN, LIPI, serta berbagai lembaga riset di kementerian dan instansi lainnya. Saat ini, BRIN dipimpin oleh Laksana Tri Handoko yang sebelumnya menjabat sebagai Kepala LIPI. Dalam menjalankan fungsinya, BRIN bertanggung jawab dalam pemantauan, pengendalian, dan evaluasi terhadap pelaksanaan tugas dan fungsi Badan Riset dan Inovasi Daerah (BRIDA) sesuai dengan ketentuan peraturan perundang-undangan yang berlaku. Berdasarkan Peraturan Presiden Nomor 78 Tahun 2021 tentang BRIN yang ditandatangani Presiden Jokowi pada 24 Agustus 2021, Pasal 3 menetapkan bahwa BRIN bertugas membantu Presiden dalam menyelenggarakan tugas pemerintahan di bidang penelitian, pengembangan, pengkajian, dan penerapan ilmu pengetahuan serta invensi dan inovasi, termasuk pengelolaan ketenaganukliran dan keantariksaan secara nasional yang terintegrasi. Selain itu, sesuai dengan ketentuan dalam Peraturan Presiden Nomor 78 Tahun 2021 Bab V Pasal 59 tentang Jabatan, Pengangkatan dan Pemberhentian, pada tanggal 28 April 2021 Presiden Joko Widodo resmi melantik Laksana Tri Handoko sebagai Kepala BRIN di Istana Negara. Keputusan ini tertuang dalam Keputusan Presiden Republik Indonesia (Keppres) Nomor 19/M Tahun 2021 tanggal 28 April 2021 tentang Pengangkatan Kepala BRIN.

4.1.2 Visi, Misi, dan Tujuan BRIN

BRIN memiliki visi yaitu terwujudnya Badan Riset dan Inovasi Nasional yang andal, profesional, inovatif, dan berintegritas dalam pelayanan kepada Presiden dan Wakil Presiden, untuk mewujudkan Visi dan Misi Presiden berupa “Indonesia Maju yang Berdaulat, Mandiri, dan Berkepribadian berlandaskan Gotong Royong”. Untuk mewujudkan visi tersebut, BRIN

menetapkan berbagai misi sebagai bagian dari strategi perencanaannya. Misi yang dimiliki BRIN yaitu:

1. Memberikan dukungan teknis dan administrasi serta analisis yang cepat, akurat dan responsif, kepada Presiden dan Wakil Presiden dalam menyelenggarakan penelitian, pengembangan, pengkajian dan penerapan, serta invensi dan inovasi, penyelenggaraan ketenaganukliran, dan penyelenggaraan keantariksaan secara nasional yang terintegrasi serta melakukan monitoring pengendalian dan evaluasi terhadap pelaksanaan tugas dan fungsi BRIDA.
2. Meningkatkan kualitas sumber daya manusia dan prasarana riset dan inovasi penyelenggaraan ketenaganukliran, dan keantariksaan secara nasional yang terintegrasi dan pembinaan terhadap pelaksanaan tugas dan fungsi BRIDA.
3. Menyelenggarakan pelayanan yang efektif dan efisien di bidang pengawasan, administrasi umum, informasi, dan hubungan kelembagaan.

Dalam rangka mewujudkan Visi dan Misi tersebut, BRIN menetapkan tiga tujuan utama, yaitu:

1. Terwujudnya temuan, terobosan dan pembaharuan ilmu pengetahuan dari hasil penelitian, pengembangan, pengkajian dan penerapan, serta invensi dan inovasi, penyelenggaraan ketenaganukliran, dan penyelenggaraan keantariksaan dalam rangka peningkatan produktivitas dan daya saing, peningkatan kualitas lingkungan hidup dan ketahanan bencana, serta iklim (T1)
2. Terwujudnya sumber daya manusia, infrastruktur, fasilitasi dan pemanfaatan riset dan inovasi yang unggul dan kompetitif (T2)
3. Terwujudnya Tata Kelola Pemerintahan di Badan Riset dan Inovasi Nasional yang baik dan bersih (T3)

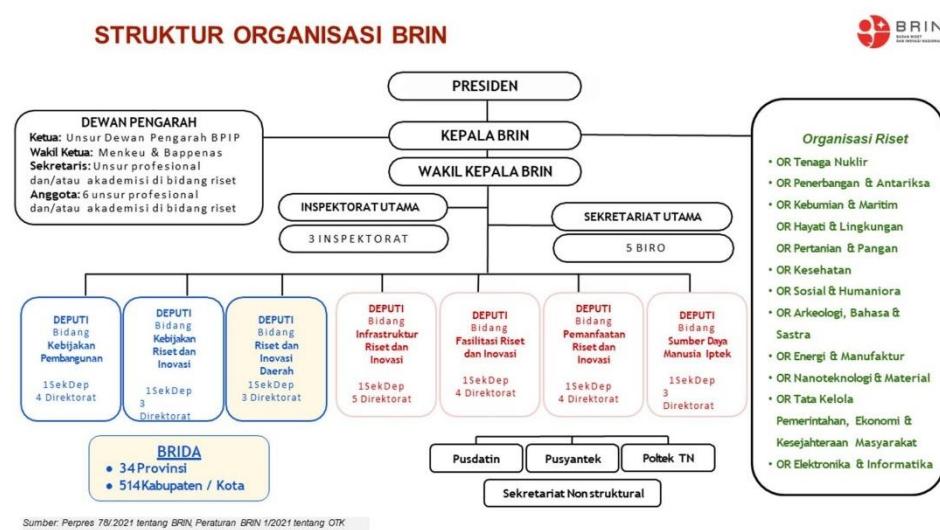
4.1.3 Struktur Organisasi BRIN

Struktur organisasi Badan Riset dan Inovasi Nasional (BRIN) dibentuk berdasarkan Peraturan Presiden Nomor 78 Tahun 2021. Pada bagian tertinggi terdapat Dewan Pengarah yang terdiri atas Ketua, Wakil Ketua, Sekretaris, dan anggota. Ketua Dewan berasal dari unsur Dewan Pengarah BPIP, Wakil Ketua berasal dari perwakilan Kementerian Keuangan dan Bappenas, serta Sekretaris dan anggota berasal dari kalangan profesional maupun akademisi di bidang riset. Di bawah Dewan Pengarah, Presiden memegang kewenangan tertinggi dalam sistem pemerintahan, termasuk dalam hal riset dan inovasi nasional.

Presiden membawahi langsung Kepala BRIN, yang bertanggung jawab penuh atas pelaksanaan fungsi BRIN secara keseluruhan. Dalam menjalankan tugasnya, Kepala BRIN dibantu oleh Wakil Kepala BRIN yang mengawasi dua komponen utama, yaitu Inspektorat Utama yang terdiri dari 3 inspektorat, dan Sekretariat Utama yang memiliki 5 biro untuk menangani urusan administrasi dan tata kelola organisasi. BRIN juga memiliki tujuh deputi, yaitu Deputi Bidang Kebijakan Pembangunan, Deputi Bidang Kebijakan Riset dan Inovasi,

Deputi Bidang Riset dan Inovasi Daerah, Deputi Bidang Infrastruktur Riset dan Inovasi, Deputi Bidang Fasilitasi Riset dan Inovasi, Deputi Bidang Pemanfaatan Riset dan Inovasi, dan Deputi Bidang Sumber Daya Manusia IPTEK. Setiap deputi membawahi beberapa sekretariat deputi (SekDep) dan direktorat yang menyesuaikan dengan lingkup tugasnya.

BRIN juga mengelola unit pelaksana non-struktural, yaitu Pusdatin (Pusat Data dan Informasi), Pusyantek (Pusat Layanan Teknologi), dan Potek TN (Pusat Teknologi Nuklir). Di tingkat daerah, terdapat BRIDA (Badan Riset dan Inovasi Daerah) yang berperan dalam mendukung kegiatan riset di tingkat daerah dan tersebar di seluruh provinsi dan kabupaten/kota. Dalam pelaksanaan riset, BRIN memiliki 13 Organisasi Riset (OR) yang berfokus menangani bidang tertentu, seperti Tenaga Nuklir; Penerbangan dan Antariksa; Kebumian dan Maritim; Hayati dan Lingkungan; Pertanian dan Pangan; Kesehatan; Sosial dan Humaniora; Arkeologi, Bahasa, dan Sastra; Energi dan Manufaktur; Nanoteknologi dan Material; Tata Kelola Pemerintahan, Ekonomi dan Kesejahteraan Masyarakat; serta Elektronika dan Informatika. Dengan struktur ini, BRIN berperan sebagai pusat riset dan inovasi nasional yang terorganisir secara sistematis untuk mendukung kemajuan ilmu pengetahuan dan teknologi di Indonesia. Adapun struktur organisasi BRIN dapat dilihat pada **Gambar 4.2**



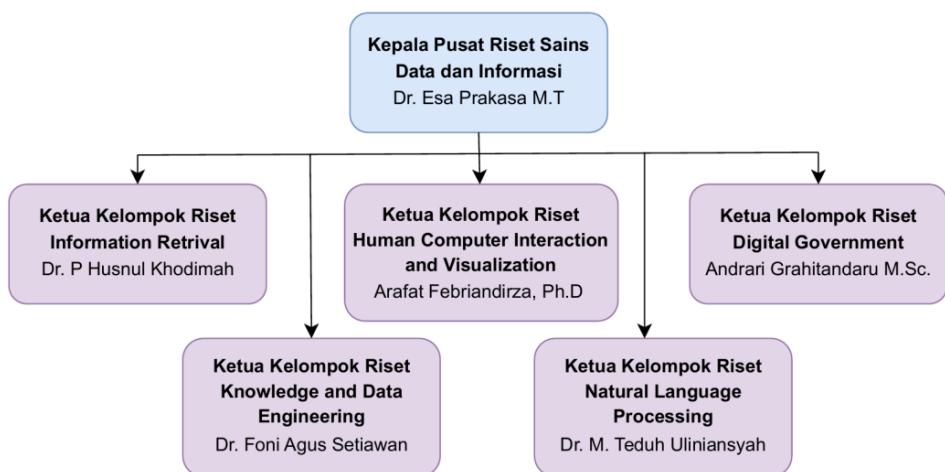
Gambar 4.2 Struktur Organisasi BRIN

Sumber: brin.go.id, 2025

4.1.4 Profil Pusat Riset Sains Data dan Informasi

Pusat Riset Sains Data dan Informasi (PRSDI) merupakan salah satu dari enam pusat riset yang berada di bawah naungan Organisasi Riset Elektronika dan Informatika. Organisasi ini berfokus pada penelitian di bidang teknologi informasi dan komunikasi serta berlokasi di BRIN KST Samaun Samadikun. Dalam perkembangannya, berbagai pusat riset di dalam organisasi ini mengembangkan berbagai teknologi, seperti kecerdasan buatan (*artificial intelligence*) dan big data. Organisasi Riset Elektronika dan

Informatika membawahi beberapa pusat riset, seperti Pusat Riset Kecerdasan Artifisial dan Keamanan Siber, Pusat Riset Elektronika, Pusat Riset Mekatronika Cerdas, Pusat Riset Telekomunikasi, Pusat Riset Sains Data dan Informasi, serta Pusat Riset Komputasi. PRSDI didirikan dengan tujuan untuk mendukung pendidikan serta menjalin kerja sama internasional dalam berbagai pertukaran pengetahuan dan teknologi. Visi PRSDI adalah menjadi pelopor dalam penelitian sains dan manajemen data yang berkontribusi terhadap inovasi di tingkat global. Di sisi lain, misi PRSDI mencakup pengembangan penelitian ilmiah, inovasi teknologi yang berkelanjutan, peningkatan kualitas sumber daya manusia, serta penyebarluasan ilmu pengetahuan melalui kolaborasi dan kegiatan pendidikan. Seperti yang ditunjukkan pada **Gambar 4.3**, PRSDI memiliki lima kelompok riset yang masing-masing berfokus pada bidang yang terkait. Pusat riset ini dipimpin oleh Dr. Esa Prakasa, M.T., selaku Kepala Pusat Riset Sains Data dan Informasi. Kelima kelompok riset tersebut mencakup *Information Retrieval*, *Knowledge and Data Engineering*, *Natural Language Processing*, *Digital Government*, serta *Human-Computer Interaction and Visualization*. Struktur organisasi PRSDI dapat ditemukan pada **Gambar 4.3**



Gambar 4.3 Struktur Organisasi PRSDI

Sumber: Dokumentasi Pribadi, 2025

4.2 *Image Collection*

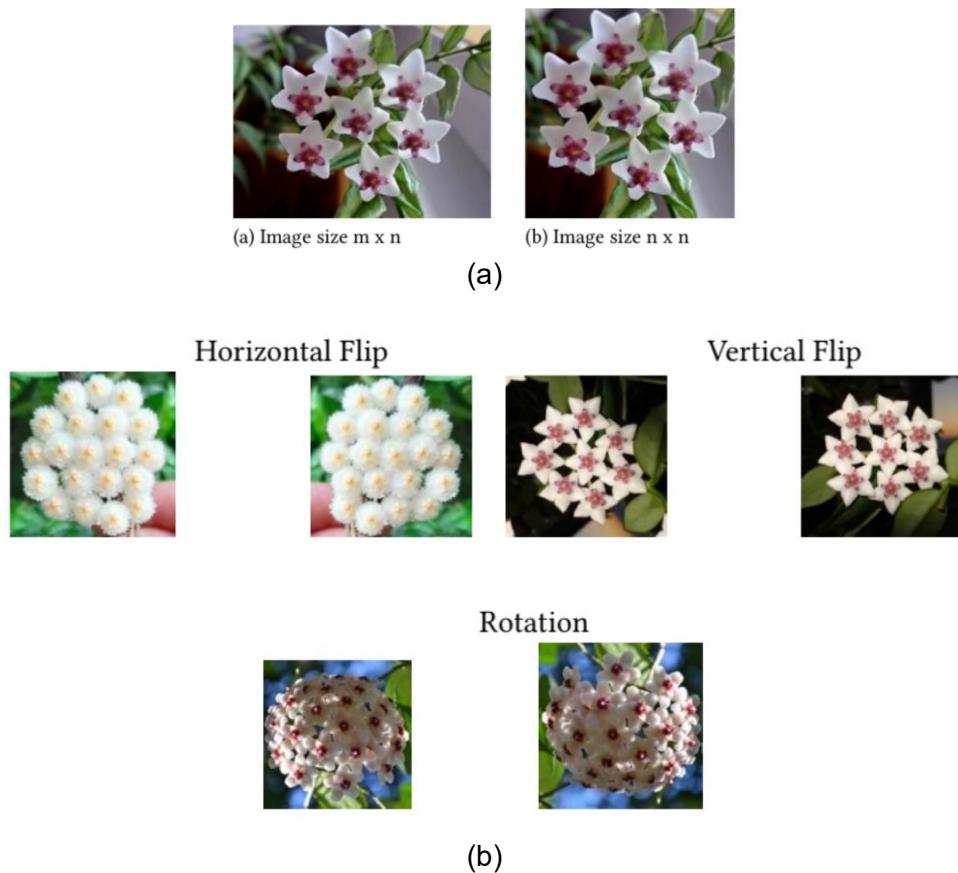
Image collection atau pengumpulan citra adalah sekumpulan gambar yang dikumpulkan dan disimpan secara bersamaan sebagai bagian dari suatu *dataset*. *Image collection* merupakan proses pengumpulan dan pengorganisasian gambar dari berbagai sumber untuk keperluan analisis, klasifikasi, atau pemrosesan lebih lanjut. Dalam penelitian, kumpulan gambar sering digunakan sebagai *dataset* untuk model kecerdasan buatan, pengenalan pola, dan analisis data visual. *Image collection* merupakan tahap awal dalam penelitian yang bertujuan untuk mendapatkan *dataset* yang akan digunakan dalam pelatihan model. Pada umumnya, teknik untuk merangkum kumpulan gambar dilakukan dengan memilih

gambar yang paling representatif dalam koleksi tersebut. Proses ini dapat dilakukan secara manual atau otomatis, bergantung pada kebutuhan dan metode yang digunakan. Sebagai bagian dari proses pengumpulan data, *image collection* berperan penting dalam penelitian karena kualitas *dataset* yang digunakan akan menentukan kualitas hasil yang diperoleh. Data yang kurang memadai atau tidak akurat dapat menghambat validitas temuan penelitian (Taherdoost, 2021).

4.3 Data *Preprocessing*

Dalam pemodelan, terdapat proses yang disebut *data preprocessing*. Sebelum data dari suatu citra dapat digunakan, data tersebut harus diproses terlebih dahulu agar memenuhi standar yang sesuai untuk tahap selanjutnya. Data *preprocessing* merupakan tahap awal dalam pemrosesan data yang bertujuan untuk membersihkan, mengorganisir, dan mengonversi data mentah agar siap digunakan dalam analisis atau pelatihan model. Tahap ini sangat penting dalam penelitian berbasis data, terutama dalam bidang kecerdasan buatan dan pembelajaran mesin, karena kualitas data yang kurang baik atau buruk dapat menyebabkan hasil yang tidak akurat atau bias (Daniswara dan Nuryana, 2023). Dalam pemrosesan citra, *preprocessing* berfungsi untuk meningkatkan kualitas citra dengan menyesuaikan kontras dan kecerahan (*brightness*), menghilangkan *noise*, melakukan restorasi citra, menerapkan transformasi citra, serta menentukan area yang akan dianalisis. Salah satu teknik *preprocessing* yaitu mengonversi citra asli berwarna (RGB) menjadi citra keabuan (*grayscale*). Pada citra *grayscale*, setiap piksel direpresentasikan dengan satu nilai intensitas dalam rentang antara 0-255, sedangkan citra berwarna, setiap piksel membutuhkan tiga nilai intensitas dalam rentang yang sama untuk setiap saluran warna (R, G, dan B). Semakin tinggi nilai intensitas (mendekati 255), maka semakin terang tingkat keabuan. Proses konversi ini dilakukan dengan meratakan tiga nilai RGB menjadi satu nilai keabuan, sehingga citra lebih sederhana dan lebih efisien untuk diproses dan dianalisis lebih lanjut (Yudhana *et al.*, 2016). Selain itu, dalam beberapa kasus, dilakukan proses *cropping* untuk menyesuaikan ukuran citra dari yang awalnya bervariasi $m \times n$ menjadi ukuran seragam $n \times n$ piksel. Fokus utama dari proses ini adalah mempertahankan objek utama, seperti bunga, serta mempertimbangkan resolusi citra asli. Proses *resizing* juga dilakukan dengan mengubah resolusi citra, karena perbedaan resolusi dapat memengaruhi kinerja model dalam melakukan pengenalan pola. *Resizing* bertujuan untuk menyeragamkan ukuran citra dan mengurangi beban komputasi, sehingga lebih sesuai untuk model pembelajaran mesin. Selanjutnya, terdapat augmentasi citra yang dilakukan untuk menghasilkan citra baru dalam *dataset* dengan menerapkan berbagai transformasi pada citra asli. Teknik augmentasi data yang sering digunakan yaitu rotasi, *flipping* horizontal, dan *flipping* vertikal (Laxmi *et al.*, 2022). Tujuan utama dari augmentasi adalah meningkatkan jumlah data latih, sehingga model dapat mengenali lebih banyak variasi citra dan memiliki kemampuan yang lebih baik dalam mengenali pola pada data baru yang belum pernah dipelajari sebelumnya. Dengan memperluas variasi data, model menjadi lebih tahan terhadap *overfitting*. Augmentasi dapat dilakukan dengan menyesuaikan tingkat kecerahan (*brightness*) secara acak, yaitu menambah atau mengurangi intensitas pencahayaan. Teknik ini bertujuan untuk

memperkenalkan variasi tambahan dalam data latih dengan mengubah tingkat pencahayaan, sehingga model lebih adaptif dalam mengenali objek meskipun terdapat variasi kondisi pencahayaan pada citra yang digunakan (Pratama dan Anggraeny, 2023). **Gambar 4.4** menunjukkan proses augmentasi *dataset*, termasuk *resize*, *flipping* horizontal, *flipping* vertikal, dan rotasi.



Gambar 4.4 Proses Augmentasi *Dataset*

Sumber: Laxmi *et al.*, 2022

4.4 Modelling

Tahap pemodelan atau *modelling* merupakan proses utama dalam pengembangan sistem berbasis *machine learning*, di mana model dirancang, dilatih, dan diuji untuk menghasilkan prediksi atau klasifikasi yang akurat. Sebelum masuk tahap pemodelan, *dataset* yang telah melewati tahap *pre-processing* dan augmentasi umumnya dibagi menjadi tiga bagian, yaitu data pelatihan (*train* data) untuk melatih model, data validasi (*validation* data) untuk mengevaluasi kinerja model selama pelatihan, dan data uji (*test* data) untuk mengukur kinerja akhir model setelah pelatihan selesai. Pemilihan model atau arsitektur sangat bergantung pada jenis permasalahan yang ingin diselesaikan, misalnya model CNN seperti MobileNet atau DenseNet yang sering digunakan untuk klasifikasi gambar. Setelah model dipilih, proses pelatihan dilakukan dengan menggunakan *dataset* yang telah diproses sebelumnya. Model akan belajar mengenali pola dalam data dengan menyesuaikan bobot berdasarkan hasil prediksi dibandingkan

dengan nilai sebenarnya. Proses ini dilakukan secara bertahap hingga model mencapai tingkat akurasi yang optimal (Akbari *et al.*, 2023).

4.4.1 MobileNetV2

MobileNetV2 adalah salah satu arsitektur *convolutional neural network* (CNN) yang dirancang agar efisien dalam komputasi dan dioptimalkan untuk penggunaan pada perangkat dengan keterbatasan sumber daya seperti ponsel atau *mobile*. Arsitektur ini mengimplementasikan teknik *depthwise separable convolution* untuk mengurangi jumlah parameter dan operasi komputasi, sehingga memungkinkan penghematan dalam penggunaan sumber daya. Kelebihan utama MobileNetV2 adalah kemampuannya untuk berjalan pada perangkat dengan keterbatasan sumber daya (komputasi terbatas), namun kekurangannya adalah tingkat akurasinya yang mungkin lebih rendah jika dibandingkan dengan model yang lebih kompleks seperti Vision Transformer (ViT), terutama untuk tugas deteksi yang membutuhkan tingkat presisi yang tinggi dan analisis mendalam (Nuriyadin, 2024).

4.4.2 DenseNet121

DenseNet121 merupakan arsitektur CNN yang menghubungkan setiap keluaran dari satu lapisan ke lapisan berikutnya, sehingga memungkinkan keluaran dari setiap lapisan dimanfaatkan kembali sebagai *input* di lapisan berikutnya. Setiap blok dalam struktur DenseNet121 saling terhubung dengan blok lainnya, sehingga blok terakhir dapat memanfaatkan keluaran dari blok yang pertama. Pendekatan ini memastikan bahwa setiap blok tidak hanya menerima *input* dari lapisan sebelumnya, tetapi juga dari seluruh blok sebelumnya, sehingga memungkinkan pemanfaatan kembali informasi di seluruh jaringan dan meningkatkan aliran gradien. Keunggulan dari struktur ini adalah kemampuannya dalam mengurangi risiko *vanishing gradient* dan mempercepat proses pelatihan, sehingga menjadikannya lebih efisien dalam mempelajari representasi fitur yang kompleks. Sebagai hasilnya, DenseNet121 sangat efektif untuk tugas-tugas klasifikasi dan deteksi gambar yang membutuhkan pemahaman fitur yang kompleks (Alfiansyah dan Litanianda, 2024).

4.5 Evaluation

Tahapan evaluasi adalah proses penting untuk menilai kinerja model yang telah dilatih dengan menggunakan berbagai metrik pengukuran. Evaluasi bertujuan untuk mengetahui seberapa baik model mampu mengklasifikasikan data baru secara akurat serta mengidentifikasi aspek yang perlu diperbaiki. Evaluasi model dimulai dengan pembuatan *confusion matrix* untuk menganalisis distribusi prediksi yang dihasilkan. Kemudian, dilanjutkan perhitungan metrik seperti akurasi, *precision*, *recall*, dan *F1-score* untuk mengukur kinerja model secara menyeluruh. *Confusion matrix* adalah sebuah tabel atau matriks yang digunakan untuk mengevaluasi efektivitas model klasifikasi dengan membandingkan hasil prediksi dengan kelas yang sebenarnya. Matriks ini terdiri dari empat elemen utama. Elemen pertama adalah *True Positive* (TP), yaitu mengacu pada kondisi ketika kelas sebenarnya positif dan model berhasil memprediksi dengan benar sebagai positif. Elemen kedua adalah *True Negative* (TN), dimana kelas sebenarnya

negatif dan model juga memprediksi dengan benar sebagai negatif. Elemen ketiga adalah *False Positive* (FP), yang terjadi ketika model memprediksi kelas sebagai positif, tetapi sebenarnya negatif. Terakhir adalah *False Negative* (FN), yang terjadi ketika model memprediksi kelas sebagai negatif, tetapi sebenarnya adalah positif (Sa'idah *et al.*, 2022).

Tabel 4.1 Confusion Matrix

		Kelas Prediksi		Total
		Benar	Salah	
Kelas Aktual	Benar	TP	FN	P
	Salah	FP	TN	N
	Total	P'	N'	P + N

Sumber: Sa'idah *et al.*, 2022

Setelah menyusun *confusion matrix* seperti pada **Tabel 4.1**, dapat dihitung metrik kinerja seperti akurasi, presisi, *recall*, dan *F1-score*. Menurut Fitriyah *et al.* (2023), akurasi adalah persentase total item yang berhasil diklasifikasikan dengan benar untuk setiap spesies. Rumus akurasi yaitu:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \dots \dots \dots \text{(Fitriyah } et al., 2023)$$

Presisi adalah persentase item yang diklasifikasikan dengan benar, dibandingkan dengan seluruh prediksi positif yang dibuat oleh sistem, yang mencerminkan ketepatan hasil yang diberikan. Rumus presisi yaitu:

$$\text{Precision} = \frac{TP}{TP + FP} \dots \dots \dots \text{(Fitriyah } et al., 2023)$$

Recall adalah persentase item yang teridentifikasi dengan benar dari seluruh item yang seharusnya teridentifikasi, tanpa memperhitungkan kesalahan positif. Rumus *recall* yaitu:

$$\text{Recall} = \frac{TP}{TP + FN} \dots \dots \dots \text{(Fitriyah } et al., 2023)$$

Skor F-1 adalah rata-rata tertimbang antara presisi dan recall, memberikan keseimbangan antara kedua metrik. Rumus Skor F-1 yaitu:

$$\text{F1 Score} = \frac{2 \times P \times R}{P + R} \dots \dots \dots \text{(Fitriyah } et al., 2023)$$

Keterangan:

TP: *True Positive*

TN: *True Negative*

FP: *False Positive*

FN: *False Negative*

BAB V

TUGAS KHUSUS

PERBANDINGAN ARSITEKTUR CONVOLUTIONAL NEURAL NETWORK (CNN) DALAM IDENTIFIKASI SPESIES TANAMAN HOYA BERDASARKAN CITRA BUNGA DI BRIN SAMAUN SAMADIKUN BANDUNG

5.1 Studi Literatur

Pada tahap evaluasi untuk identifikasi spesies tanaman Hoya berdasarkan citra bunga, pemilihan arsitektur CNN yang tepat merupakan langkah awal yang krusial. Oleh karena itu, dilakukan studi literatur untuk mengeksplorasi berbagai penelitian terkait identifikasi spesies tanaman menggunakan metode *deep learning*, khususnya *Convolutional Neural Network* (CNN). Pada **Lampiran 6**. menyajikan perbandingan beberapa penelitian yang telah dilakukan sebelumnya dalam identifikasi spesies tanaman menggunakan berbagai arsitektur CNN. Berdasarkan hasil penelitian yang telah dianalisis, CNN terbukti memiliki tingkat akurasi yang lebih tinggi dibandingkan metode *machine learning* lainnya. Beberapa arsitektur CNN, seperti DenseNet121 dan MobileNetV2, menunjukkan performa yang sangat baik dengan tingkat akurasi yang kompetitif. Hal ini menunjukkan bahwa pemilihan arsitektur CNN yang optimal dapat meningkatkan akurasi dalam identifikasi spesies tanaman Hoya berdasarkan citra bunga.

5.2 Data Collecting

Pada tahap awal, diperlukan *dataset* yang berisi beberapa spesies tanaman hoya yang digunakan untuk pemrosesan model *deep learning*. Pada tugas khusus ini, digunakan dua *dataset* yang diperoleh dari RIN Dataverse, yang merupakan *dataset* gambar dan dari internet (*website* plantnet dan vermonthoyas). RIN Dataverse merupakan platform yang menyediakan sekitar 47 ribu *dataset* dan lebih dari 329 ribu file data. Ukuran *file* terbesar yang terdapat di RIN Dataverse mencapai 7 terabyte. *Dataset* tanaman hoya yang terdapat di RIN Dataverse memiliki jumlah gambar sebanyak 106 gambar yang dibagi menjadi lima folder berdasarkan kelas spesiesnya. Dalam *dataset* ini terdapat lima label kelas, yaitu *Hoya amicabilis*, *Hoya campanulata white*, *Hoya multiflora*, *Hoya rigidifolia*, dan *Hoya scorchedinii*. Pada kelas *H. amicabilis* memiliki data citra digital sebanyak 18 gambar, *H. campanulata white* sebanyak 32 gambar, *H. multiflora* sebanyak 18 gambar, *H. rigidifolia* sebanyak 12 gambar, dan *H. scorchedinii* sebanyak 26 gambar. Sementara itu, *dataset* yang didapatkan dari internet (*website* plantnet dan vermonthoyas), berisi total 15 gambar yang sudah terbagi menjadi lima folder berdasarkan kelas spesies. Jumlah gambar per kelas pada *dataset* ini adalah *H. amicabilis* sebanyak 3 gambar, *H. campanulata white* sebanyak 2 gambar, *H. multiflora* sebanyak 6 gambar, *H. rigidifolia* sebanyak 2 gambar, dan *H. scorchedinii* sebanyak 2 gambar. Contoh data untuk masing-masing kelas dapat dilihat pada **Gambar 5.1**



Gambar 5.1 Dataset Tanaman Hoya

Sumber: RIN Dataverse

5.3 Data Preprocessing

Proses pengumpulan data citra daun Hoya melalui proses *cropping* dan *resizing* bertujuan untuk menjaga konsistensi dalam pemrosesan oleh model *deep learning*. Seluruh gambar disesuaikan menjadi ukuran 224×224 piksel untuk mengurangi beban komputasi dan mempercepat proses pelatihan model. Total gambar bunga yang diperoleh terdiri dari 106 gambar dari *dataset* RIN Dataverse dan 121 gambar yang merupakan kombinasi *dataset* RIN Dataverse serta *dataset* dari internet. Proses *preprocessing* dan augmentasi citra dilakukan menggunakan platform Roboflow, yang menyediakan tampilan antarmuka visual untuk menyediakan berbagai transformasi gambar secara efisien dan sistematis. Berbagai teknik augmentasi diterapkan melalui Roboflow untuk meningkatkan jumlah data latih dan memperkaya variasi citra pada *dataset*, seperti *flipping* horizontal dan vertikal, rotasi 90° , *cropping* (zoom hingga 20%), *shear* ($\pm 10^\circ$ Horizontal, $\pm 10^\circ$ Vertical), konversi *grayscale* (20%), penambahan *noise* (0,85%), rotasi dengan sudut antara -15° and $+15^\circ$, serta penambahan efek blur hingga 2,5 piksel. Selain itu, proses normalisasi dilakukan dengan mengaplikasikan fitur *auto-orient* untuk menyesuaikan orientasi gambar secara otomatis, sehingga arah tampilan citra menjadi konsisten dan lebih optimal untuk diproses oleh model. Setelah augmentasi selesai, Roboflow juga digunakan untuk membagi *dataset* secara otomatis ke dalam tiga kelompok data, yaitu pelatihan (*training*), validasi (*validation*), dan pengujian (*testing*). Setelah seluruh proses augmentasi, jumlah gambar bertambah menjadi 254 dan 291 gambar, yang selanjutnya digunakan dalam tahap pelatihan dan evaluasi model. Langkah ini diharapkan dapat meningkatkan akurasi model dalam mengidentifikasi spesies tanaman Hoya. Hasil gambar setelah proses augmentasi dapat dilihat pada **Gambar 5.2**



Gambar 5.2 Bunga Hoya di Augmentasi

Sumber: Data Pribadi, 2025

Dalam penelitian ini, citra bunga Hoya diproses dalam format RGB untuk mempertahankan informasi warna yang dinilai sebagai salah satu fitur penting dalam membedakan antarspesies. Warna bunga yang khas pada beberapa spesies Hoya dapat mendukung proses klasifikasi, sehingga konversi ke *grayscale* dianggap berpotensi menghilangkan informasi relevan tersebut. Hal ini sejalan dengan penelitian oleh Gowda dan Yuan (2019), yang menyatakan bahwa sebagian besar proses klasifikasi citra dilakukan langsung menggunakan format RGB tanpa transformasi warna tambahan, karena pada banyak kasus representasi warna asli sudah cukup untuk membantu model mengenali objek dengan baik, dan beberapa jenis objek bahkan lebih akurat diklasifikasikan dalam ruang warna tertentu. Meski demikian, penggunaan RGB dapat menyebabkan tantangan seperti sensitivitas terhadap pencahayaan dan variasi kualitas gambar. Untuk mengatasi hal tersebut, dilakukan teknik augmentasi dan normalisasi pencahayaan guna menjaga konsistensi citra dan meningkatkan kestabilan input pada proses pelatihan model.

5.4 Modelling

Dataset yang telah melewati tahap preprocessing dan augmentasi kemudian dibagi menjadi tiga kategori, yaitu *train* data, *validation* data, dan *test* data. *Train* data digunakan dalam proses pelatihan model untuk mengenali pola dan fitur pada citra, sehingga model dapat mempelajari dan mengingat hubungan antara *input* dan *output* yang benar. *Validation* data berfungsi sebagai parameter evaluasi selama proses pelatihan untuk mengevaluasi performa model dalam mengidentifikasi citra secara akurat. Sementara itu, *test* data digunakan pada tahap akhir untuk menguji kinerja model untuk menilai tingkat akurasi dalam melakukan klasifikasi gambar. Pembagian *dataset* dilakukan dengan rasio 70% untuk *train* data, 20% untuk *validation* data, dan 10% untuk *test* data. Dengan rasio ini, jumlah gambar dalam *dataset* RIN Dataverse terdiri dari 222 gambar untuk *train* data, 23 gambar untuk *validation* data, dan 9 gambar untuk *test* data. Sementara itu, untuk kombinasi *dataset* RIN Dataverse dan *dataset* dari internet, jumlah data yang diperoleh yaitu 255 gambar untuk *train* data, 23 gambar untuk *validation* data, dan 13 gambar untuk *test* data. Proses pembagian *dataset* dapat dilihat melalui *code* yang ditampilkan pada **Gambar 5.3**

```
# Rasio pembagian data
train_ratio = 0.70
val_ratio = 0.20
test_ratio = 0.10
```

Gambar 5.3 Code Pembagian *Dataset*

Sumber: Data diolah, 2025

Setelah melewati tahap *preprocessing*, augmentasi, dan pembagian dataset, terjadi perubahan dalam jumlah data akhir untuk masing-masing dari lima kelas pada tiga kategori data. Pada *dataset* RIN Dataverse, *train* data terdiri dari 222

gambar yang digunakan dalam proses pelatihan arsitektur dengan distribusi sebagai berikut, yaitu kelas *H. amicabilis* memiliki 30 gambar, kelas *H. campanulata white* sebanyak 72 gambar, kelas *H. multiflora* sebanyak 36 gambar, kelas *H. rigidifolia* sebanyak 30 gambar, dan kelas *H. scortechinii* sebanyak 54 gambar. Sementara itu, *validation* data terdiri dari 23 gambar yang digunakan untuk mengevaluasi performa arsitektur selama proses pelatihan. Data tersebut mencakup 5 gambar untuk kelas *H. amicabilis*, 5 gambar untuk kelas *H. campanulata white*, 4 gambar untuk kelas *H. multiflora*, 2 gambar untuk kelas *H. rigidifolia*, dan 7 gambar untuk kelas *H. scortechinii*. Pada tahap pengujian, *test* data berisi 9 gambar yang digunakan untuk mengukur akurasi arsitektur dalam mengklasifikasikan citra. Distribusi gambar dalam kategori ini adalah 3 gambar untuk kelas *H. amicabilis*, 3 gambar untuk kelas *H. campanulata white*, 2 gambar untuk kelas *H. multiflora*, dan 1 gambar untuk kelas *H. scortechinii*. Untuk kombinasi *dataset RIN Dataverse* dan *dataset* dari internet, *train* data terdiri dari 255 gambar digunakan dalam proses pelatihan arsitektur, dengan distribusi sebagai berikut, yaitu kelas *H. amicabilis* memiliki 42 gambar, kelas *H. campanulata white* sebanyak 72 gambar, kelas *H. multiflora* sebanyak 54 gambar, kelas *H. rigidifolia* sebanyak 36 gambar, dan kelas *H. scortechinii* sebanyak 51 gambar. *Validation* data terdiri dari 23 gambar yang digunakan untuk mengevaluasi kinerja arsitektur selama proses pelatihan. Data tersebut mencakup 5 gambar untuk kelas *H. amicabilis*, 6 gambar untuk kelas *H. campanulata white*, 3 gambar untuk kelas *H. multiflora*, 1 gambar untuk kelas *H. rigidifolia*, dan 8 gambar untuk kelas *H. scortechinii*. Pada tahap pengujian, *test* data berisi 13 gambar yang digunakan untuk menilai akurasi arsitektur dalam mengklasifikasikan citra. Distribusi gambar dalam kategori ini adalah 2 gambar untuk kelas *H. amicabilis*, 4 gambar untuk kelas *H. campanulata white*, 3 gambar untuk kelas *H. multiflora*, 1 gambar untuk kelas *H. rigidifolia*, dan 3 gambar untuk kelas *H. scortechinii*. Pembagian ini dirancang untuk memastikan keseimbangan dalam proses pelatihan, validasi, dan pengujian arsitektur sehingga meningkatkan performa dalam mengidentifikasi citra tanaman Hoya secara akurat.

5.4.1 Dataset RIN Dataverse

5.4.1.1 Arsitektur MobileNetV2

Model MobileNetV2 dirancang dengan menggunakan platform berupa Google Colab yang dapat diakses melalui *web browser* berbasis *online*. Eksekusi perintah dilakukan menggunakan *runtime CPU*, karena terdapat keterbatasan penggunaan dari T4 GPU yang hanya tersedia untuk pengguna premium di Google Colab. Model MobileNetV2 dilatih dengan menggunakan 10 *epoch* dengan *batch* yang sesuai dengan *train generator* serta menggunakan fungsi *loss categorical_crossentropy* untuk mengoptimalkan kinerja model. Proses pelatihan ini bertujuan untuk menghasilkan model klasifikasi gambar yang optimal dengan akurasi yang tinggi. Perancangan arsitektur MobileNetV2 disusun dalam bentuk pseudocode berikut untuk memberikan gambaran alur implementasi model secara sistematis:

```

# Load arsitektur MobileNetV2
base_model = MobileNetV2(weights='imagenet', include_top=False, input_shape=(224, 224, 3))
base_model.trainable = False # Freeze layer awal

# Tambahkan lapisan tambahan
x = base_model.output
x = GlobalAveragePooling2D()(x)
x = Dense(128, activation='relu')(x)
output_layer = Dense(len(train_generator.class_indices), activation='softmax')(x)

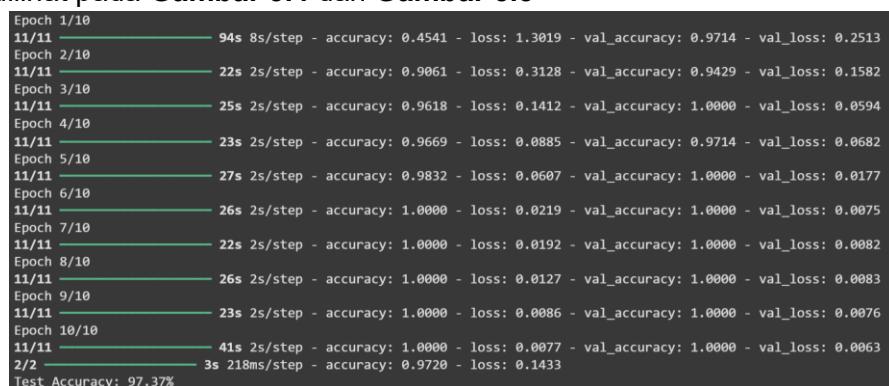
model = Model(inputs=base_model.input, outputs=output_layer)

# Kompilasi model
model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])

# Latih model
history = model.fit(
    train_generator,
    epochs=10,
    validation_data=val_generator
)

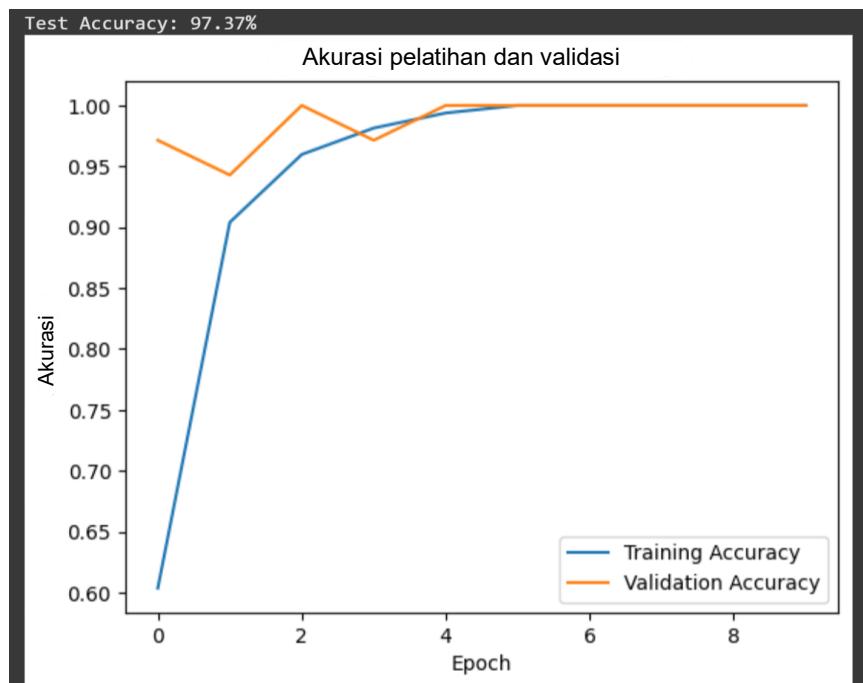
```

Selama proses pelatihan dan validasi, tingkat akurasi yang diperoleh dianalisis pada setiap epoch untuk menilai kinerja model. Pada grafik yang dihasilkan, terlihat bahwa akurasi selama pelatihan mengalami peningkatan yang signifikan dari *epoch* awal hingga akhir, mendekati nilai 100%. Di sisi lain, akurasi validasi cenderung stabil dengan fluktuasi kecil di awal sebelum akhirnya mencapai nilai maksimum yang sama dengan akurasi pelatihan. Berdasarkan grafik, akurasi tertinggi selama pelatihan mencapai 100% dengan tren peningkatan yang konsisten. Akurasi validasi juga menunjukkan hasil yang sangat tinggi sejak awal dan tetap berada di angka maksimal setelah beberapa *epoch*. Nilai akurasi yang diperoleh dari proses pengujian dengan arsitektur MobileNetV2 dan dataset RIN Dataverse tergolong tinggi, yaitu mencapai 97,37%. Pola ini menunjukkan bahwa model telah belajar dengan baik dan berhasil mencapai performa optimal dengan perbedaan minimal antara akurasi pelatihan dan validasi. Grafik akurasi dan hasil pelatihan untuk MobileNetV2 dapat dilihat pada **Gambar 5.4** dan **Gambar 5.5**



Gambar 5.4 Hasil Pelatihan dan Akurasi Model MobileNetV2

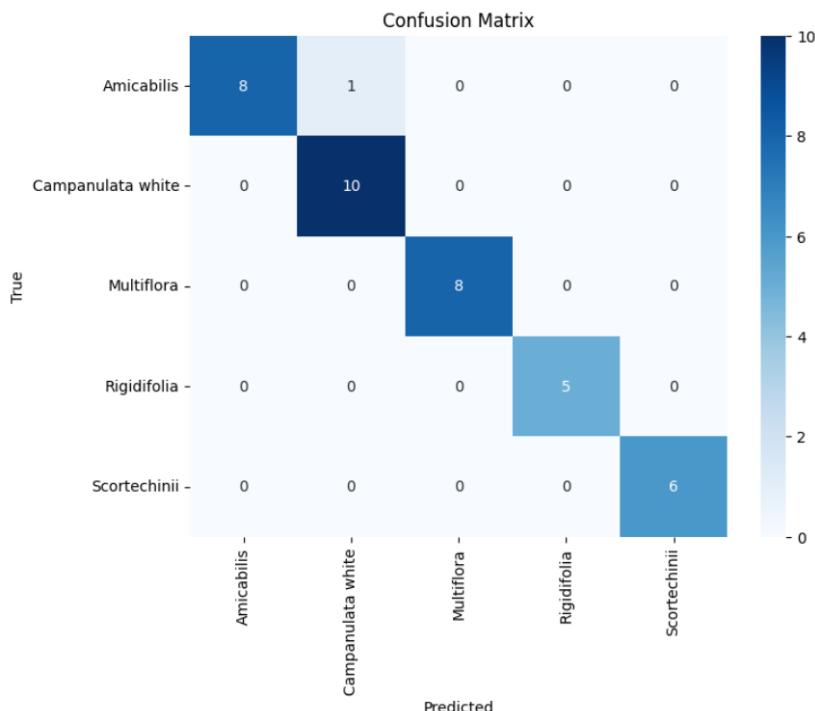
Sumber: Data diolah, 2025



Gambar 5.5 Grafik Akurasi MobileNetV2

Sumber: Data diolah, 2025

Setelah dilakukan proses pelatihan dan validasi, langkah berikutnya adalah pengujian (*testing*) untuk menilai kinerja model yang telah dibangun. Pada tahap ini, digunakan *confusion matrix* untuk mengevaluasi hasil klasifikasi, baik yang benar maupun yang salah. Diagram ini juga digunakan untuk menghitung akurasi yang dihasilkan selama proses pengujian. Berdasarkan *confusion matrix* yang diperoleh, sebagian besar prediksi model telah sesuai dengan data sebenarnya, menunjukkan bahwa model memiliki performa yang baik dalam mengklasifikasikan berbagai kategori. Akan tetapi, terdapat beberapa kesalahan prediksi, salah satunya pada kelas *Amicabilis*, di mana satu sampel dikategorikan sebagai kelas lain. Kesalahan ini dapat disebabkan oleh kemiripan fitur antar kelas, seperti bentuk dan warna, sehingga model mengalami kesulitan dalam membedakannya. Meskipun terdapat kesalahan, hasil klasifikasi menunjukkan akurasi yang tinggi. Nilai akurasi yang diperoleh dari proses pengujian dengan arsitektur MobileNetV2 dan *dataset* RIN Dataverse tergolong tinggi, yaitu mencapai 97,37%, yang menunjukkan bahwa model ini dapat bekerja dengan baik dalam mengidentifikasi kategori yang telah ditentukan. Grafik *confusion matrix* untuk MobileNetV2 dapat dilihat pada **Gambar 5.6**.



Gambar 5.6 Grafik Confusion Matrix MobileNetV2

Sumber: Data diolah, 2025

5.4.1.2 Arsitektur DenseNet121

Model DenseNet121 dirancang dengan menggunakan platform berupa Google Colab yang dapat diakses melalui *web browser* berbasis *online*. Eksekusi perintah dilakukan menggunakan *runtime CPU*, karena terdapat keterbatasan penggunaan dari T4 GPU yang hanya tersedia untuk pengguna premium di Google Colab. Model DenseNet121 dilatih dengan menggunakan 10 *epoch* dengan ukuran *batch* yang disesuaikan dengan *train generator* serta menggunakan fungsi *loss categorical_crossentropy* untuk mengoptimalkan kinerja model. Proses pelatihan ini bertujuan untuk menghasilkan model klasifikasi gambar yang optimal dengan tingkat akurasi yang tinggi. Perancangan arsitektur DenseNet121 disusun dalam bentuk pseudocode berikut untuk memberikan gambaran alur implementasi model secara sistematis:

```
# Load arsitektur DenseNet121
base_model = DenseNet121(weights='imagenet', include_top=False, input_shape=(224, 224, 3))
base_model.trainable = False # Freeze layer awal

# Tambahkan lapisan tambahan
x = base_model.output
x = GlobalAveragePooling2D()(x)
x = Dense(128, activation='relu')(x)
output_layer = Dense(len(train_generator.class_indices), activation='softmax')(x)

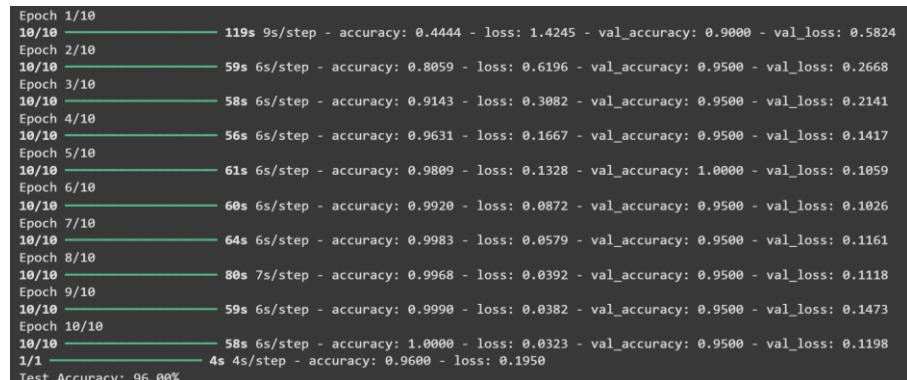
model = Model(inputs=base_model.input, outputs=output_layer)

# Kompilasi model
model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
```

```
# Latih model
history = model.fit(
    train_generator,
    epochs=10,
    validation_data=val_generator
)
```

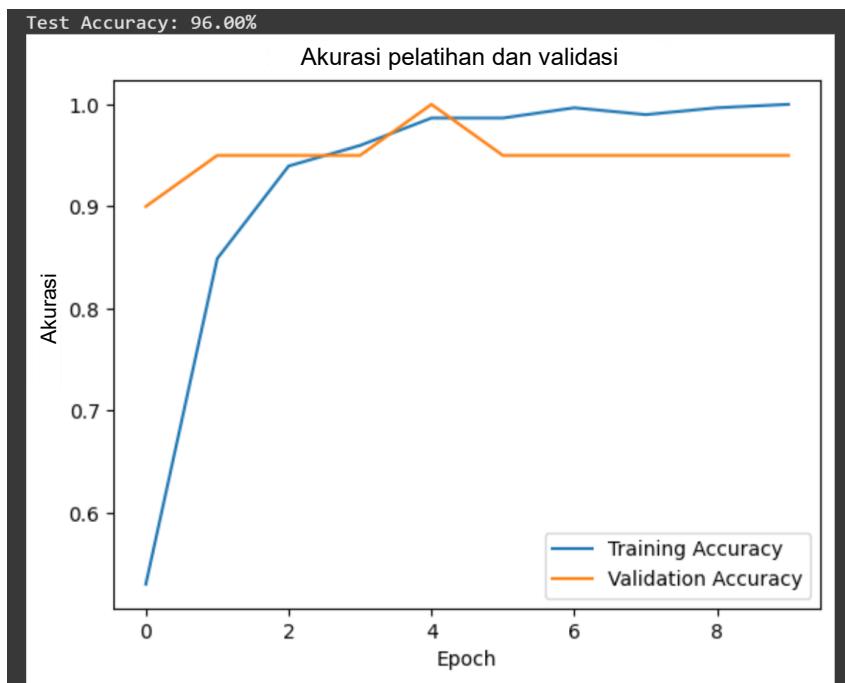
Selama proses pelatihan dan validasi, dilakukan analisis terhadap akurasi yang diperoleh pada setiap *epoch*. Berdasarkan grafik yang ditampilkan, akurasi pelatihan mengalami peningkatan secara signifikan sejak *epoch* awal dan hampir mencapai nilai 100% pada *epoch* terakhir. Sementara itu, akurasi validasi menunjukkan tren yang relatif stabil setelah mencapai nilai tinggi di awal, dengan sedikit fluktuasi di pertengahan *epoch* sebelum akhirnya stabil di angka mendekati 100%. Akurasi tertinggi selama pelatihan hampir mencapai nilai 100%, sedangkan akurasi validasi sedikit lebih rendah tetapi tetap berada di angka yang sangat baik. Nilai akurasi yang diperoleh dari proses pengujian dengan arsitektur DenseNet121 dan dataset RIN Dataverse tergolong tinggi, yaitu mencapai 96,00%. Hal ini menunjukkan bahwa model berhasil belajar dengan baik dan menunjukkan performa yang optimal tanpa memiliki tanda-tanda *overfitting* yang signifikan. Grafik akurasi dan hasil pelatihan untuk DenseNet121 dapat dilihat pada

Gambar 5.7 dan Gambar 5.8



Gambar 5.7 Hasil Pelatihan dan Akurasi Model DenseNet121

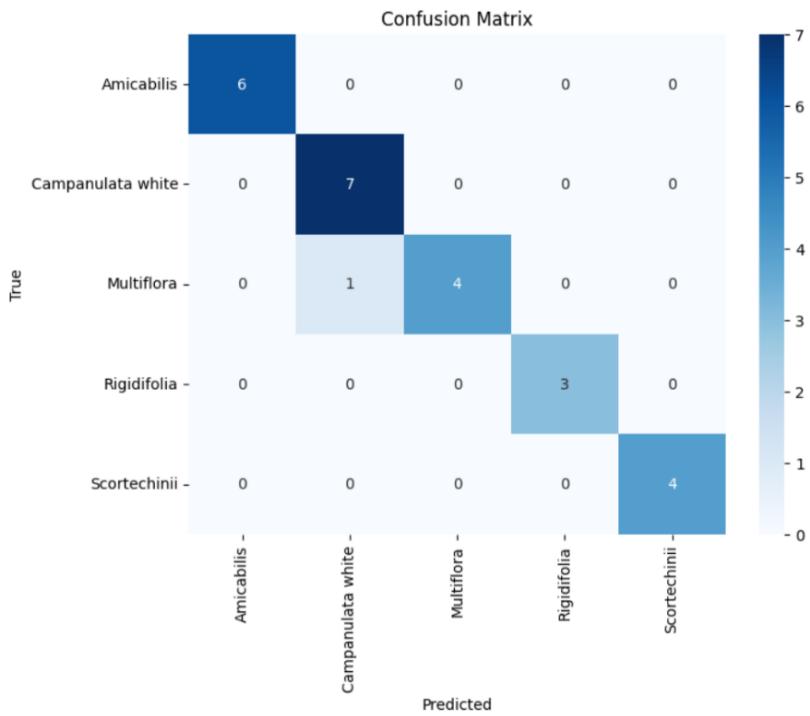
Sumber: Data diolah, 2025



Gambar 5.8 Grafik Akurasi DenseNet121

Sumber: Data diolah, 2025

Setelah dilakukan proses pelatihan dan validasi, tahap berikutnya adalah pengujian (*testing*) untuk menilai performa model yang telah dikembangkan. Pada tahap ini, *confusion matrix* digunakan untuk mengevaluasi akurasi klasifikasi, baik yang benar maupun yang salah. Berdasarkan *confusion matrix* yang ditampilkan, sebagian besar prediksi model sesuai dengan data sebenarnya, menunjukkan bahwa model memiliki kinerja yang cukup baik. Akan tetapi, terdapat beberapa kesalahan klasifikasi, khususnya pada kelas *Multiflora*, di mana satu sampel diklasifikasikan sebagai *Campanulata white*. Kesalahan ini dapat terjadi disebabkan oleh kemiripan karakteristik visual antara kedua kelas, sehingga model mengalami kesulitan dalam membedakannya. Secara keseluruhan, hasil pengujian menunjukkan bahwa model mampu mengklasifikasikan kategori dengan tingkat akurasi yang cukup tinggi, meskipun masih terdapat peluang untuk perbaikan guna mengurangi tingkat kesalahan dalam identifikasi. Nilai akurasi yang diperoleh dari proses pengujian dengan menggunakan arsitektur DenseNet121 dan *dataset* RIN Dataverse tergolong tinggi, yaitu mencapai 96,00%. Grafik *confusion matrix* untuk DenseNet121 dapat dilihat pada **Gambar 5.9**.



Gambar 5.9 Grafik Confusion Matrix MobileNetV2

Sumber: Data diolah, 2025

5.4.2 Kombinasi Dataset RIN Dataverse dengan Dataset Internet

5.4.2.1 Arsitektur MobileNetV2

Model MobileNetV2 dirancang dengan menggunakan platform berupa Google Colab yang dapat diakses melalui *web browser* berbasis *online*. Eksekusi perintah dilakukan menggunakan *runtime CPU*, karena terdapat keterbatasan penggunaan dari T4 GPU yang hanya tersedia untuk pengguna premium di Google Colab. Model MobileNetV2 dilatih dengan menggunakan 10 *epoch* dengan *batch* yang sesuai dengan *train generator* serta menggunakan fungsi *loss categorical_crossentropy* untuk mengoptimalkan kinerja model. Proses pelatihan ini bertujuan untuk menghasilkan model klasifikasi gambar yang optimal dengan akurasi yang tinggi. Perancangan arsitektur MobileNetV2 disusun dalam bentuk pseudocode berikut untuk memberikan gambaran alur implementasi model secara sistematis:

```
# Load arsitektur MobileNetV2
base_model = MobileNetV2(weights='imagenet', include_top=False, input_shape=(224, 224, 3))
base_model.trainable = False # Freeze layer awal

# Tambahkan lapisan tambahan
x = base_model.output
x = GlobalAveragePooling2D()(x)
x = Dense(128, activation='relu')(x)
output_layer = Dense(len(train_generator.class_indices), activation='softmax')(x)

model = Model(inputs=base_model.input, outputs=output_layer)

# Kompilasi model
```

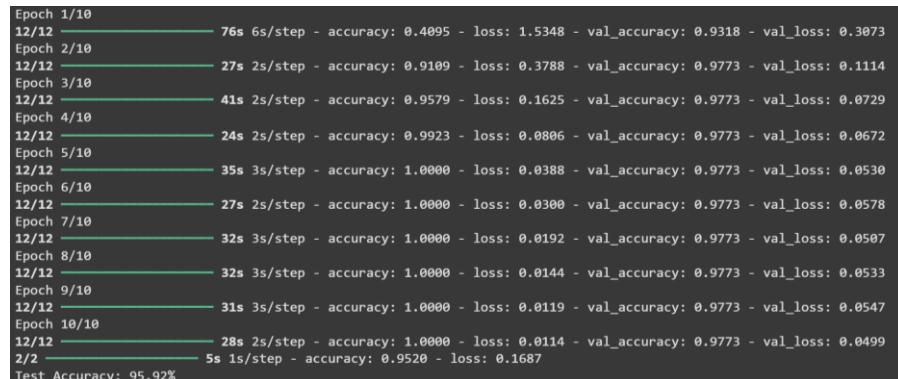
```

model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])

# Latih model
history = model.fit(
    train_generator,
    epochs=10,
    validation_data=val_generator
)

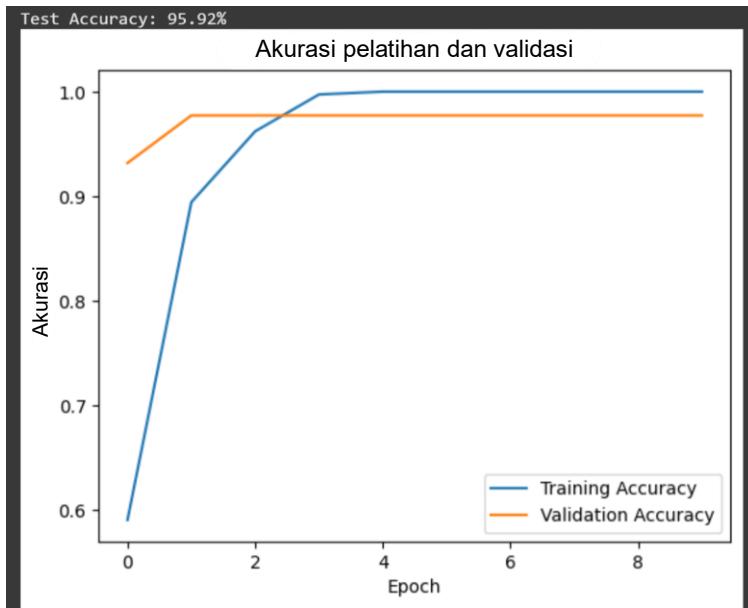
```

Selama proses pelatihan dan validasi, dilakukan analisis terhadap tingkat akurasi yang diperoleh pada setiap *epoch*. Berdasarkan grafik yang ditampilkan, terlihat bahwa akurasi pelatihan mengalami peningkatan yang cepat dari awal hingga mencapai angka mendekati 100% setelah beberapa *epoch*. Sementara itu, akurasi validasi dimulai dengan nilai yang tinggi dan cenderung stabil setelah mencapai titik tertentu, dengan sedikit fluktuasi pada tahap awal. Berdasarkan grafik, akurasi tertinggi selama pelatihan mencapai 100%, sedangkan akurasi validasi tetap berada di sekitar 98%. Nilai akurasi yang diperoleh dari proses pengujian dengan arsitektur MobileNetV2 dan dataset kombinasi (RIN Dataverse + Internet) tergolong tinggi, yaitu mencapai 95,92%. Pola ini menunjukkan bahwa model belajar dengan sangat baik, dengan performa yang optimal dan perbedaan kecil antara akurasi pelatihan dan validasi, yang mengindikasikan minimnya terjadi *overfitting*. Grafik akurasi dan hasil pelatihan untuk MobileNetV2 dapat dilihat pada **Gambar 5.10** dan **Gambar 5.11**



Gambar 5.10 Hasil Pelatihan dan Akurasi Model MobileNetV2

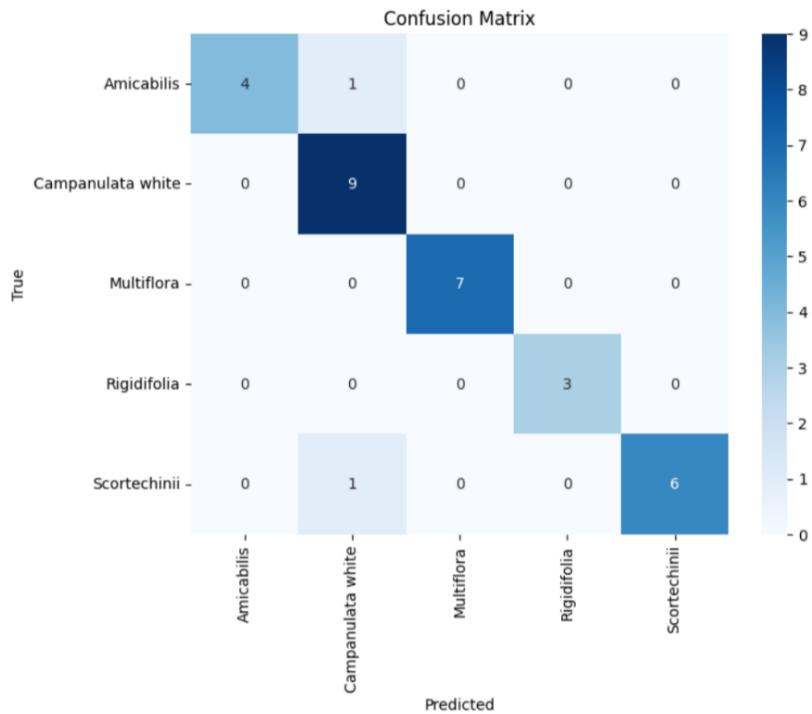
Sumber: Data diolah, 2025



Gambar 5.11 Grafik Akurasi MobileNetV2

Sumber: Data diolah, 2025

Setelah proses pelatihan dan validasi, pengujian dilakukan untuk mengevaluasi kinerja model yang telah dibangun. *Confusion matrix* digunakan untuk menganalisis tingkat akurasi serta kesalahan klasifikasi. Berdasarkan *confusion matrix* yang diperoleh, sebagian besar prediksi model telah sesuai dengan data sebenarnya. Akan tetapi, terdapat beberapa kesalahan klasifikasi, seperti pada kelas *Amicabilis*, di mana satu sampel diklasifikasikan sebagai *Campanulata white*, serta kelas *Scortechinii* yang satu sampel diklasifikasikan sebagai *Campanulata white*. Kesalahan ini mungkin terjadi disebabkan oleh kesamaan karakteristik visual antara beberapa kelas. Secara keseluruhan, hasil pengujian menunjukkan bahwa model memiliki performa yang cukup baik dalam mengklasifikasikan data, meskipun terdapat beberapa kesalahan yang masih perlu diperbaiki untuk meningkatkan akurasi. Nilai akurasi yang diperoleh dari proses pengujian dengan menggunakan arsitektur MobileNetV2 dan dataset kombinasi (RIN Dataverse + Internet) tergolong tinggi, yaitu mencapai 95,92%. Grafik *confusion matrix* untuk MobileNetV2 dapat dilihat pada **Gambar 5.12**



Gambar 5.12 Grafik Confusion Matrix MobileNetV2

Sumber: Data diolah, 2025

5.4.2.2 Arsitektur DenseNet121

Model DenseNet121 dirancang dengan menggunakan platform berupa Google Colab yang dapat diakses melalui *web browser* berbasis *online*. Eksekusi perintah dilakukan menggunakan *runtime CPU*, karena terdapat keterbatasan penggunaan dari T4 GPU yang hanya tersedia untuk pengguna premium di Google Colab. Model DenseNet121 dilatih dengan menggunakan 10 *epoch* dengan ukuran *batch* yang disesuaikan dengan *train generator* serta menggunakan fungsi *loss categorical_crossentropy* untuk mengoptimalkan kinerja model. Proses pelatihan ini bertujuan untuk menghasilkan model klasifikasi gambar yang optimal dengan tingkat akurasi yang tinggi. Perancangan arsitektur DenseNet121 disusun dalam bentuk pseudocode berikut untuk memberikan gambaran alur implementasi model secara sistematis:

```
# Load arsitektur DenseNet121
base_model = DenseNet121(weights='imagenet', include_top=False, input_shape=(224, 224, 3))
base_model.trainable = False # Freeze layer awal

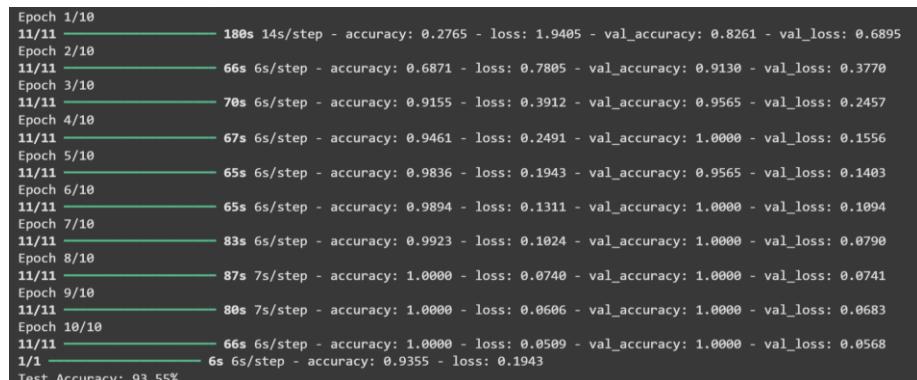
# Tambahkan lapisan tambahan
x = base_model.output
x = GlobalAveragePooling2D()(x)
x = Dense(128, activation='relu')(x)
output_layer = Dense(len(train_generator.class_indices), activation='softmax')(x)

model = Model(inputs=base_model.input, outputs=output_layer)

# Kompilasi model
model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
```

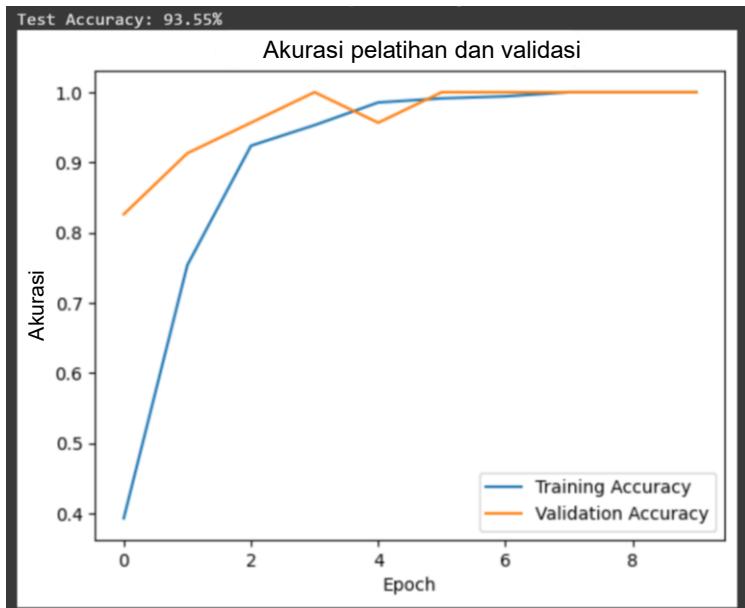
```
# Latih model
history = model.fit(
    train_generator,
    epochs=10,
    validation_data=val_generator
)
```

Selama proses pelatihan dan validasi, dilakukan analisis terhadap tingkat akurasi pada setiap *epoch* untuk mengevaluasi performa model. Berdasarkan grafik yang ditampilkan, terlihat bahwa akurasi pelatihan menunjukkan peningkatan signifikan dari awal hingga mendekati nilai 100%. Sementara itu, akurasi validasi dimulai dengan nilai yang cukup tinggi dan terus mengalami peningkatan hingga mencapai titik stabil mendekati 100%, meskipun terjadi sedikit fluktuasi di tengah proses pelatihan. Berdasarkan grafik, akurasi tertinggi selama pelatihan hampir mencapai 100% dan akurasi validasi juga menunjukkan hasil yang sangat baik dengan nilai yang hampir sama. Nilai akurasi yang diperoleh dari proses pengujian dengan arsitektur DenseNet121 dan *dataset* kombinasi (RIN Dataverse + Internet) tergolong tinggi, yaitu mencapai 93,55%. Hal ini menunjukkan bahwa model memiliki performa yang sangat baik dengan minim terjadinya *overfitting*. Grafik akurasi dan hasil pelatihan untuk DenseNet121 dapat dilihat pada **Gambar 5.13** dan **Gambar 5.14**



Gambar 5.13 Hasil Pelatihan dan Akurasi Model DenseNet121

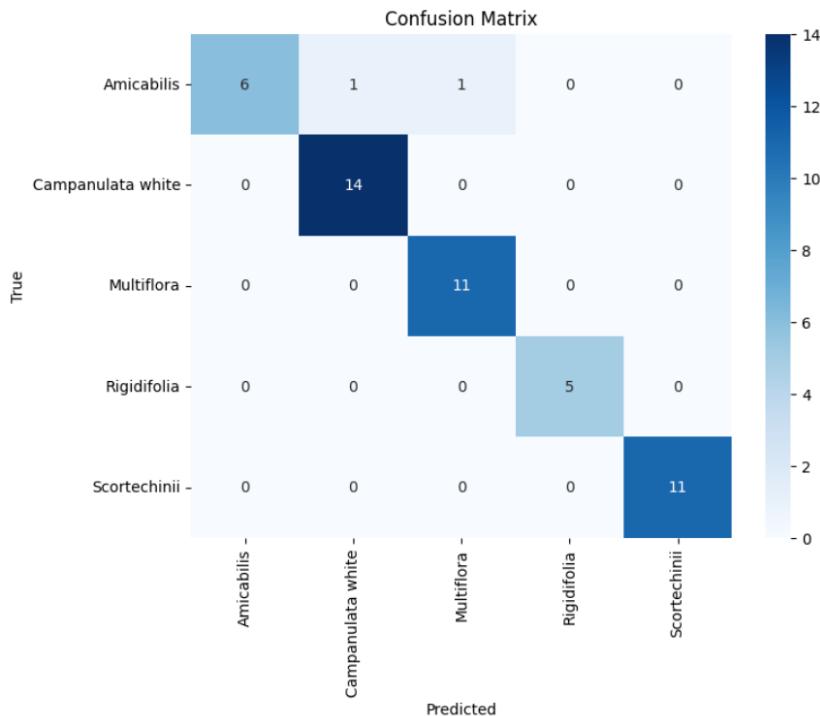
Sumber: Data diolah, 2025



Gambar 5.14 Grafik Akurasi DenseNet121

Sumber: Data diolah, 2025

Setelah tahap pelatihan dan validasi, dilakukan pengujian untuk mengevaluasi kinerja model yang telah dikembangkan. *Confusion matrix* digunakan untuk menganalisis hasil klasifikasi, baik yang benar maupun yang salah. Berdasarkan *confusion matrix* yang diperoleh, model berhasil mengklasifikasikan sebagian besar data dengan benar. Akan tetapi, masih terdapat beberapa kesalahan klasifikasi, seperti pada kelas *Amicabilis*, di mana dua sampel diklasifikasikan secara salah sebagai *Campanulata white* dan *Multiflora*. Kesalahan ini dapat terjadi karena kemiripan visual antar kelas. Secara keseluruhan, model telah menunjukkan kinerja yang baik dalam pengujian dengan jumlah kesalahan yang relatif rendah, yang menandakan bahwa model memiliki tingkat akurasi yang cukup tinggi. Nilai akurasi yang diperoleh dari proses pengujian dengan menggunakan arsitektur DenseNet121 dan *dataset* kombinasi (RIN Dataverse + Internet) tergolong tinggi, yaitu mencapai 93,55%. Grafik *confusion matrix* untuk DenseNet121 dapat dilihat pada **Gambar 5.15**



Gambar 5.15 Grafik Confusion Matrix DenseNet121

Sumber: Data diolah, 2025

5.5 Perbandingan Arsitektur

Setelah tahap pelatihan dan pengujian terhadap masing-masing arsitektur, langkah terakhir adalah mengevaluasi kinerja arsitektur menggunakan *confusion matrix*. Evaluasi ini bertujuan untuk membandingkan akurasi setiap arsitektur berdasarkan dua jenis *dataset* yang digunakan, yaitu *dataset* RIN Dataverse dan kombinasi *dataset* RIN Dataverse dengan *dataset* dari internet. Hasil evaluasi ditampilkan pada **Tabel 5.1** menunjukkan bahwa pada *dataset* RIN Dataverse, arsitektur MobileNetV2 mencapai akurasi tertinggi sebesar 97,37%, sedangkan DenseNet121 memperoleh akurasi sebesar 96,00%. Sementara itu, pada *dataset* kombinasi RIN Dataverse dan *dataset* dari internet, MobileNetV2 memperoleh akurasi sebesar 95,92%, sedangkan DenseNet121 memperoleh akurasi 93,55%. Berdasarkan hasil ini, dapat disimpulkan bahwa MobileNetV2 menunjukkan kinerja yang lebih baik dibandingkan DenseNet121 pada kedua skenario *dataset* yang digunakan. Secara keseluruhan, hasil terbaik diperoleh pada kombinasi arsitektur MobileNetV2 dengan *dataset* RIN Dataverse, yang menghasilkan akurasi tertinggi sebesar 97,37%.

Tabel 5.1 Perbandingan Kinerja Arsitektur

Arsitektur	Dataset	Accuracy
MobileNetV2	RIN Dataverse	97,37%
	Kombinasi (RIN Dataverse + Internet)	95,92%
DenseNet121	RIN Dataverse	96,00%
	Kombinasi (RIN Dataverse + Internet)	93,55%

Sumber: Data diolah, 2025

BAB VI

PENUTUP

6.1 Kesimpulan

Pelaksanaan kegiatan PKL yang berjudul “Perbandingan Arsitektur *Convolutional Neural Network* (CNN) dalam Identifikasi Spesies Tanaman Hoya Berdasarkan Citra Bunga di BRIN Samaun Samadikun Bandung” terdapat beberapa kesimpulan yang diperoleh, yaitu:

1. Pemahaman terhadap struktur organisasi dan operasional KST Samaun Samadikun BRIN diperoleh melalui pengamatan terhadap pembagian fungsi kerja, pola komunikasi internal, serta pelaksanaan kegiatan riset di lingkungan kerja yang relevan.
2. Penelitian terkait biodiversitas tanaman Hoya yang dilakukan di BRIN melibatkan proses identifikasi spesies berbasis citra digital, pengumpulan *dataset* dari berbagai sumber, serta analisis terhadap karakteristik morfologi bunga sebagai parameter utama dalam proses klasifikasi spesies.
3. Tahapan pengembangan model *deep learning* untuk pengolahan citra bunga tanaman Hoya berhasil dilakukan, dimulai dari tahapan pengumpulan data, *preprocessing*, augmentasi, pembagian *dataset*, hingga penerapan model *Convolutional Neural Network* (CNN). Dua arsitektur CNN yang diterapkan, yaitu MobileNetV2 dan DenseNet121, menunjukkan kinerja yang baik dalam mengklasifikasikan lima spesies tanaman Hoya. Berdasarkan hasil evaluasi menggunakan *confusion matrix*, arsitektur MobileNetV2 dengan *dataset* RIN Dataverse memperoleh akurasi tertinggi yaitu sebesar 97,37%. Oleh karena itu, arsitektur MobileNetV2 dinilai sebagai pilihan yang paling optimal dalam klasifikasi citra spesies tanaman Hoya pada penelitian ini.

6.2 Saran

Dalam pelaksanaan penelitian ini, terdapat beberapa saran yang dapat menjadi bahan pengembangan lebih lanjut untuk meningkatkan akurasi dan efektivitas model yang digunakan:

1. Memperluas Jenis Tanaman Hoya: Menambahkan lebih banyak spesies dan varietas Hoya untuk meningkatkan akurasi identifikasi.
2. Menambah Jumlah Gambar per Spesies: Menambahkan lebih banyak gambar untuk setiap spesies guna meningkatkan akurasi dan ketahanan model.
3. Eksplorasi Arsitektur CNN Lainnya: Mengevaluasi kinerja arsitektur CNN lainnya seperti EfficientNet atau ResNet untuk membandingkan performa dengan MobileNetV2 dan DenseNet121.

DAFTAR PUSTAKA

- Afifah N, Yulia ND, Soetopo L, Respatijarti. 2017. Analisis kekerabatan tanaman hoya berdasarkan karakter morfologi di upi balai konservasi tumbuhan kebun raya purwodadi-lipi-pasuruan-jawa timur. Jurnal Produksi Tanaman 5(4): 546-553.
- Akbari MFR, Rahayudi B, Muflikhah L. 2023. Implementasi *deep learning* menggunakan algoritma efficientdet untuk sistem deteksi kelayakan penerima bantuan langsung tunai berdasarkan citra rumah di wilayah kabupaten kediri. Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer 7(4): 1817-1825.
- Alfiansyah NS, Litanianda Y. 2024. Identifikasi *lumpy skin disease* menggunakan tensorflow dengan metode *convolutional neuron network*. JATI (Jurnal Mahasiswa Teknik Informatika) 8(4): 7330-7336.
- Annisa R, Fakhrurrozi Y, Rahayu S. 2017. Proses pembunganan beberapa varietas hoya coronaria dari kawasan hutan kerangas air anyir, bangka. EKOTONIA: Jurnal Penelitian Biologi, Botani, Zoologi dan Mikrobiologi 2(1): 10-19.
- Daniswara AAA, Nuryana IKD. 2023. Data *preprocessing* pola pada penilaian mahasiswa program profesi guru. JINACS: (*Journal of Informatics and Computer Science*) 5(1): 97-100.
- Darojat MD, Sari YA, Wihandika RC. 2021. *Convolutional neural network* untuk klasifikasi citra makanan khas indonesia. Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer 5(11): 4764-4769.
- Fauziah E, Sadewo FB, Putra HM, Rosyani P. 2024. Penerapan *image processing* menggunakan opencv dan python untuk memperhalus gambar melalui *smoothing image* dengan metode gaussian blur. *Indonesian Journal on Networking and Security* 13(2): 1-7.
- Firdiana ER, Renjana E. 2019. Pertumbuhan vegetatif stek daun hoya pada tiga media tanam yang berbeda. Prosiding Seminar Nasional HAYATI VII. Kediri, 20-21 September.
- Fitriyah H, Laxmi GF, Hakim SA, Kushadiani SK, Setiawan FA, Manik LP, Riyanto S, Siagian AHAM, Nur WH, Rahayu S, Apriani NF. 2023. Hoya species plant identification based on leaf and flower using convolutional neural network models. SIET. Bandung, Bali, 24-25 Oktober.
- Ghfari MAA, Sasmito AP, Rudhistiar D. 2022. Aplikasi pendekripsi kematangan tomat. JATI (Jurnal Mahasiswa Teknik Informatika) 6(1): 294-300.
- Gowda SN, Yuan C. 2019. ColorNet: Investigating the importance of color spaces for image classification. Computer Vision and Pattern Recognition.
- Hafiz P, Dorly, Rahayu S. 2013. Karakteristik anatomi daun dari sepuluh spesies hoya sukulen serta analisis hubungan kekerabatannya. Buletin Kebun Raya 16(1): 58-73.
- Hakim AR, Dorly, Rahayu S. 2013. Keragaman dan analisis kekerabatan hoya spp. bertipe daun non sukulen berdasarkan karakter anatomi daun. Buletin Kebun Raya 16(1): 1-17.

- Kusmana C, Hikmat A. 2015. Keanekaragaman hayati flora di indonesia. *Jurnal Pengelolaan Sumberdaya Alam dan Lingkungan* 5(2): 187-198.
- Laxmi GF, Kushadiani SK, Rahayu S, Nugroho B, Haryanto T. 2022. Identification of hoya plant using convolutional neural network (cnn) and transfer learning. IC3INA. Virtual Event, 22-23 November.
- Mayrantie M, Fernando T, Herawatiningsih R. 2021. Inventarisasi tumbuhan hoya (*apocynaceae*) dalam kawasan hutan lindung kecamatan jangkang kabupaten sanggau. *Jurnal Hutan Lestari* 9(3): 457-465.
- Noverina KA, Kushadiani SK, Sugiarto Y, Rahayu S, Siagian AHAM, Hendrawan Y. 2024. Identification of hoya as a medicinal plant using convolutional neural network. International Conference on Computer, Control, Informatics and its Applications (IC3INA). Bandung, Indonesia, 9-10 Oktober.
- Nuriyadin. 2024. Analisis klasifikasi gambar deteksi merokok dengan metode cnn yang ditingkatkan menggunakan model *fine tuning* pada arsitektur mobilenetv3l, efficientnetv2m, dan vision transformer. *Jurnal Ilmu Komputer* 2(1): 1-24.
- Pratama NK, Anggraeny FT. 2023. Deteksi lampu lalu lintas dan *zebra cross* menggunakan mobilenetv2 *single shot detector*. *Jurnal Informatika Kaputama (JIK)* 7(2): 225-232.
- Pujjati R, Rochmawati N. 2022. Identifikasi citra daun tanaman herbal menggunakan metode convolutional neural network (cnn). JINACS (Journal of Informatics and Computer Science) 3(3): 351-357.
- Raup A, Ridwan W, Khoeriyah Y, Supiana, Zaqiah QY. 2022. *Deep learning* dan penerapannya dalam pembelajaran. *JIIP (Jurnal Ilmiah Ilmu Pendidikan)* 5(9): 3258-3267.
- Sa'idad S, Suparta IPYN, Suhartono E. 2022. Modification of convolutional neural network googlenet architecture with dull razor filtering for classifying skin cancer. *Jurnal Nasional Teknik Elektro dan Teknologi Informasi* 11(2): 148-153.
- Septian AD, Suhendar A. 2024. Implementasi algortima *convolutional neural network* untuk deteksi penyakit daun kentang menggunakan citra digital. *Jurnal Informatika Teknologi dan Sains (JINTEKS)* 6(4): 1017-1025.
- Sun X, Xu L, Zhou Y, Shi Y. 2023. Leaves and twigs image recognition based on *deep learning* and combined classifier algorithms. *Forests* 14(6): 1-25.
- Taherdoost H. 2021. Data collection methods and tools for research; a step-by-step guide to choose data collection technique for academic and business research projects. *International Journal of Academic Research in Management (IJARM)* 10(1): 10-38.
- Wardani KRR, Leonardi L. 2023. Klasifikasi penyakit pada daun angur menggunakan metode *convolutional neural network*. *Jurnal Tekno Insentif* 17(2): 112-126.
- Yudhana A, Sunardi, Saifullah S. 2016. Perbandingan segmentasi pada citra asli dan citra kompresi wavelet untuk identifikasi telur. *Jurnal Ilmiah ILKOM* 8(3): 190-196.

LAMPIRAN

Lampiran 1. Surat Penerimaan PKL



**PUSAT RISET
SAINS DATA DAN INFORMASI**
KST Samaun Samadikun
Jalan Sangkuriang, Dago, Kecamatan Coblong Kota Bandung – 40135
Telepon/WhatsApp: 081119333608, Surel: prsdi@brin.go.id
Laman: <https://www.brin.go.id>

Nomor : B-19429/III.6.3/TU.04.01/12/2024
Sifat : Biasa
Lampiran : Satu Berkas
Hal : Tanggapan Permohonan Ijin Praktek Kerja Lapangan (PKL)
Mahasiswa Universitas Brawijaya

Bandung, 10 Desember 2024

Yth. Wakil Dekan Bidang Akademik
Universitas Brawijaya
di tempat

Menindaklanjuti Surat Nomor 05365/UN10.F1001/B/HM.01.01.1/2024 tanggal 09 Desember 2024 perihal Permohonan Ijin PKL. Dengan ini kami sampaikan bahwa kami bersedia menerima pelaksanaan Praktek Kerja Lapangan (PKL) di Pusat Riset Sains Data dan Informasi - Organisasi Riset Elektronika dan Informatika (PRSDI-OREI), Badan Riset dan Inovasi Nasional (BRIN) terhitung mulai tanggal sebagaimana terlampir.

Sehubungan dengan hal tersebut, diharapkan peserta memeriksa kembali kelengkapan dokumen dan pendaftaran lainnya pada sistem Elektronik Layanan Sains (Elsa) serta mengikuti arahan pembimbing. Dan selama pelaksanaan Kerja Praktik di Pusat Riset Sains Data dan Informasi, Pembimbing harus mendampingi Mahasiswa terutama saat berada di laboratorium.

Sebagai bentuk masukan untuk kami, silakan mengisi Survey Kepuasan Masyarakat (SKM) pada tautan <https://forms.gle/4kJzX2PC17Kg4fN56>. Untuk informasi dapat menghubungi Koordinator Layanan Humas Kawasan Bandung-Garut Sdri. Karlina Gusmarani, M.A. melalui HP/WA : +62 856-2219-685.

Demikian hal ini kami sampaikan, kami harapkan hasil kerja Praktek (Reguler) ini akan berlanjut sebagai kegiatan penelitian Tugas Akhir Mahasiswa yang bersangkutan. Atas perhatian dan kerja sama Saudara, kami ucapkan terima kasih.

Kepala Pusat Riset Sains Data dan Informasi,



Dr. Esa Prakasa, M.T.

Tembusan:

1. Sekretaris Utama;
2. Kepala Organisasi Elektronika dan Informatika;
3. Koordinator Humas Kawasan Bandung-Garut;
4. PPID Pelaksana Kawasan Bandung;
5. Koordinator Pelaksana Fungsi Pengelolaan KST Samaun Samadikun Bandung.



Dokumen ini ditandatangani secara elektronik oleh
Kepala dari BRIN, silakan
lakukan verifikasi pada dokumen
elektronik yang dapat diunduh
dengan melakukan scan QR Code

Lampiran Surat
Kepala Pusat Riset Sains Data dan Informasi
Nomor : B-19429/III.6.3/TU.04.01/12/2024
Tanggal : 10 Desember 2024

DAFTAR PESERTA PRAKTIK KERJA LAPANGAN/MAGANG
PUSAT RISET SAINS DATA DAN INFORMASI
ORGANISASI RISET ELEKTRONIKA DAN INFORMATIKA
BANDAN RISET DAN INOVASI NASIONAL

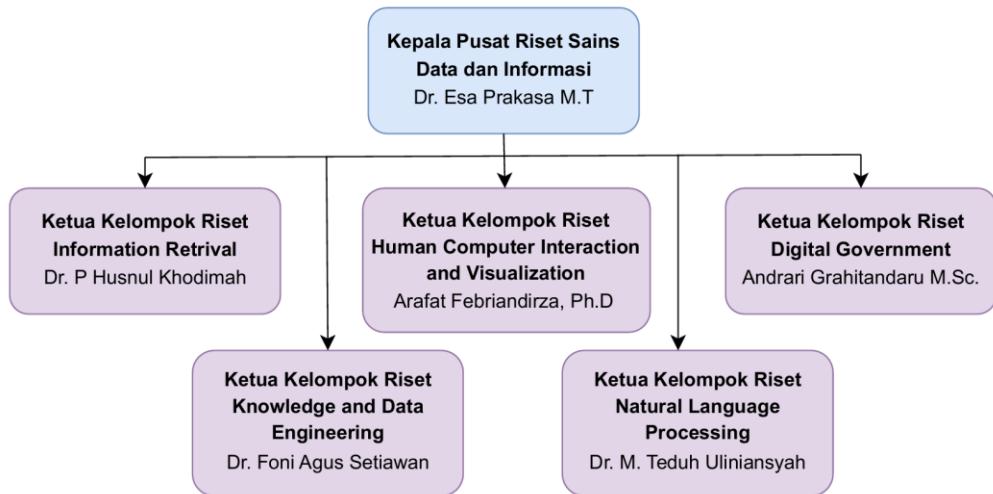
No.	Nama	Program	Pembimbing	Pelaksanaan
1	Setiyaki Aruma Nandi NIM. 225100200111038	Program Studi S-1, Departemen Teknik Biosistem, Fakultas Teknologi Pertanian Universitas Brawijaya	Wawan Hendriawan Nur, S.Si., M.T. NIP. 198207062006041019 Peneliti Ahli Muda	06 Januari 2025 s.d. 06 Februari 2025
2	Citra Mayzahra Putri NIM. 225100200111039		Siti Kania Kushadiani, S.T., M.Kom. NIP. 197906042002122007 Peneliti Ahli Muda	
3	Keiza Alfera Hummairo Assyura NIM. 225100200111008		Dr. Esa Prakasa, M.T. NIP. 197603222005021003 Peneliti Ahli Utama / Kepala Pusat Riset Sains Data dan Informasi	
4	Putri Inayah Adhinata NIM. 225100200111033		Dr. Wiwin Suwamingsih, M.T. NIP. 197303142006042002 Peneliti Ahli Madya	
5	Rahiel Zalfa Purnomo Putri NIM. 225100200111003		Irfan Asfy Fakhry Anto, S.Kom., M.T. NIP. 198707132015021002 Peneliti Ahli Muda	

Kepala Pusat Riset Sains Data dan Informasi,

 TT ELEKTRONIK

Dr. Esa Prakasa, M.T.

Lampiran 2. Struktur Organisasi Pusat Riset Sains dan Data Informasi KST BRIN
Samaun Samadikun Bandung



Lampiran 3. Kartu Kendali Pembimbing Lapang

	KEMENTERIAN PENDIDIKAN, KEBUDAYAAN, RISET, DAN TEKNOLOGI UNIVERSITAS BRAWIJAYA FAKULTAS TEKNOLOGI PERTANIAN		
NAMA : NIM : DEPARTEMEN : PROGRAM STUDI : LOKASI PKL : JUDUL PKL :	CITRA MAYZAHRA PUTRI 22510020011039 TEKNIK BIOSISTEM TEKNIK PERTANIAN DAN BIOSISTEM Badan Riset dan Inovasi Nasional (BRIN) KST. Samau Samadikun, Jl. Sangkuriang, Dago, Kec. Coblong, Kota Bandung, Jawa Barat PERBANDINGAN ARSITEKTUR CONVOLUTIONAL NEURAL NETWORK (CNN) DALAM IDENTIFIKASI SPESIES TANAMAN HOYA BERDASARKAN CITRA BUNGA DI BRIN SAMAU SAMADIKUN BANDUNG		
DOSEN PEMBIMBING:			
NO	TANGGAL	KEGIATAN KONSULTASI	TANDA TANGAN PEMBIMBING PKL
1.	6/1/2025	Sambutan, mentoring awal dari DPL, koordinasi terkait topik	
2.	7/1/2025	Melakukan literature review	
3.	8/1/2025	Melakukan literature review	
4.	9/1/2025	Melakukan literature review	
5.	10/1/2025	Melakukan literature review	
6.	13/1/2025	Melakukan Pemetaan literature review	
7.	14/1/2025	Presentasi tugas literature review, koordinasi terkait tugas lanjutan	
8.	15/1/2025	Melakukan literature review 2	
9.	16/1/2025	Melakukan literature review 2	
10.	17/1/2025	Melakukan literature review 2	
11.	20/1/2025	Melakukan pemetaan literature review 2	
12.	21/1/2025	Presentasi tugas literature review 2, konsultasi & penetapan judul	
13.	22/1/2025	Pengerjaan proposal (judul baru) dan studi literatur	
14.	23/1/2025	Melanjutkan penggeraan proposal	
15.	29/1/2025	Melanjutkan penggeraan proposal	
16.	30/1/2025	Memulai pembuatan model	
17.	31/1/2025	Melanjutkan pembuatan model	
18.	03/2/2025	Melanjutkan pembuatan model	
19.	04/2/2025	Diskusi, konsultasi, dan presentasi kepada DPL, pembuatan model	
20.	05/2/2025	Melanjutkan pembuatan model, pembuatan PPT	
21.	06/2/2025	Presentasi Bersama.	

Catatan: Tanggal Terakhir di Mitra : Kamis, 6 Februari 2025

Mengetahui,
 Dosen Pembimbing,

Lampiran 4. Form Penilaian Kegiatan PKL

LEMBAR PENILAIAN PRAKTEK KERJA LAPANG (PKL)

Yang bertanda tangan dibawah ini, kami pembimbing Praktek Kerja Lapang (PKL) mahasiswa Fakultas Teknologi Pertanian Universitas Brawijaya Malang menerangkan dengan sebenarnya bahwa :

Nama : Citra Mayzahra Putri
NIM : 225100200111039
Jurusan : Teknik Pertanian dan Biositem
Lokasi PKL : Badan Riset dan Inovasi, Maternal, BPII, KST Lamauan Samadiukun, Jl. Sangkulirang, Pago, Kec. Cepalong, Kota Bandung, Jawa Barat

Telah menyelesaikan Praktek Kerja Lapang (PKL) yang berjudul :

Dengan hasil sebagai berikut :

NO.	MATERI PENILAIAN	NILAI (ANGKA)
1	Kedisiplinan	80
2	Tanggung Jawab	80
3	Kreativitas	78
4	Kerjasama	82
	Rata-rata	

Mengetahui,
Pimpinan perusahaan,

Pembimbing Lapang,



Catatan :

Suryati

SISTEM PENILAIAN

ANGKA	NILAI (HURUF)	BOBOT
80 - 100	A	4.0
76 - 79	B+	3.5
71 - 75	B	3.0
61 - 70	C+	2.5
56 - 60	C	2.0
51 - 55	D+	1.5
45 - 50	D	1.0
0 - 44	E	0.0

Lampiran 5. Dokumentasi Kegiatan PKL





Lampiran 6. Literature Review

No.	Judul Penelitian	Penulis, Tahun	Parameter	Jumlah Spesies	Metode	Hasil
1.	Identification of Hoya Plant using Convolutional Neural Network (CNN) and Transfer Learning	Laxmi GF, Kushadiani SK, Rahayu S, Nugroho B, Haryanto T. (2022)	Citra bunga Sumber: The National Gardening Association. 2022. Plant Database.	6 spesies: <ul style="list-style-type: none"> • Australis • Carnosa • Cinnamomifolia • Kerrii • Lacunosa • Verticillata 	Arsitektur: DenseNet-121	Hasil akurasi = 90,476% or 0,90476
2.	Hoya Species Plant Identification based on Leaf and Flower using Convolutional Neural Network Models	Fitriyah H, Laxmi GF, Hakim SA, Kushadiani SK, Setiawan FA, Manik LP, Riyanto S, Siagian AHAM, Nur WH, Rahayu S, Apriani NF. (2023)	Citra daun dan bunga Sumber: <ol style="list-style-type: none"> 1. D'Hoyas, Cibinong, Indonesia 2. Vernonia Nursery, Bogor, Indonesia 3. Kebun Raya Bogor, Indonesia 4. Internet 	1. Citra daun: 26 spesies <ul style="list-style-type: none"> • Amicabilis (22) • Anulata (21) • Australis (29) • Campanulata • white (35) • Caudata (25) • Excavata (12) • Garut (20) • Gunung Lawu (24) • Incurvula (25) • Mamasa (32) • Minahassae (28) • Monetteae (35) • Obovata (24) • Occultata silver (21) • Polypus (25) • Rigidifolia (21) • Surisana (21) • Towutiensis (41) • Unchinata (33) • Vitellina (26) 	Arsitektur: DenseNet-121 dan VGG16	Hasil Akurasi Model: <ol style="list-style-type: none"> 1. DenseNet121: <ul style="list-style-type: none"> • Akurasi bunga: 67,89% • Akurasi daun: 76,09% 2. VGG16: <ul style="list-style-type: none"> • Akurasi bunga: 48,97% • Akurasi daun: 43,48%

		<ul style="list-style-type: none"> • <i>Vittelinoides</i> (34) • <i>Wallichii</i> ssp <i>Tenebrosa</i> (21) • <i>Waymaniae</i> (35) <p>2. <i>Citra bunga</i>: 28 species</p> <ul style="list-style-type: none"> • <i>Aff. Parviflora</i> (14) • <i>Aff.</i> • <i>Ranavensis</i> (10) • <i>Amicabilis</i> (18) • <i>Affinis</i> (14) • <i>Amicabilis</i> (18) • <i>Australis</i> (19) • <i>Campanulata</i> • <i>white</i> (32) • <i>Cf. Plicata</i> (10) • <i>Cinnamomifolia</i> (12) • <i>Clemensiorum</i> (16) • <i>Dolichosparte</i> (15) • <i>Finlaysonii</i> (14) • <i>Forbesii</i> (12) • <i>Garut</i> (11) • <i>Hypolasia</i> (12) • <i>Incurvula</i> (22) • <i>Latifolia</i> (11) • <i>Multiflora</i> (18) • <i>Occultata silver</i> (12) • <i>Polypus</i> (10)
--	--	---

		<ul style="list-style-type: none"> • <i>Polypus</i> kalteng (16) • <i>Rigidfolia</i> (18) • <i>Schortechinii</i> (20) • <i>Urnchinata</i> (10) 	
3.	Identification of Hoya as a Medicinal Plant Using Convolutional Neural Network	<p>Noverina KA, Kushadiani SK, Sugianto Y, Rahayu S, Siagian AHAM, Hendrawan Y. (2024)</p> <p>Citra daun Sumber: RIN Dataverse, BRIN</p>	<p>Arsitektur: VGG16 dan MobileNetV2</p> <p>Pembagian Dataset:</p> <ul style="list-style-type: none"> • Total gambar: 120 (setelah preprocessing) • Dataset pelatihan: 64% (77 gambar) • Dataset validasi: 16% (19 gambar) • Dataset pengujian: 20% (24 gambar) • VGG16: 53,33% • MobileNetV2: 80% <p>Hasil akurasi:</p> <ul style="list-style-type: none"> • MobileNetV2: 80% • VGG16: 53,33% <p>Distribusi per Spesies Hoya:</p> <ul style="list-style-type: none"> • Pelatihan: 6–12 gambar per kelas • Validasi: 2–3 gambar per kelas • Pengujian: 3–4 gambar per kelas